

课程笔记

盛颖访谈：从 SGLang 到 RadixArk 的 AI 基建之路

五道口纳什 & Claude

2026 年 8 月 4 日



视频作者/频道：硅谷 101

发布日期：2025 年

视频时长：1 小时 47 分钟

视频链接：<https://www.bilibili.com/video/BV1GaM968E6T>

目录

1 从江西到硅谷：一个基建工程师的成长之路	3
1.1 嘉宾介绍与背景概览	3
1.2 求学之路：从竞赛少女到斯坦福博士	4
1.2.1 从江西到上海交大 ACM 班	4
1.2.2 哥伦比亚大学：纽约的”放松式冲击”	4
1.2.3 斯坦福 PhD：轮转困境与导师危机	5
1.2.4 形式化验证：从被动进入到发现美感	6
1.2.5 COVID 低谷与”教科书般完美的导师”	7
1.3 Two Sigma：华尔街的半年体验	8
1.3.1 动机：智识好奇与”体验驱动”的人生哲学	8
1.3.2 Two Sigma 的组织文化：一个意外的参照系	8
1.4 本章小结	9
2 认识自己：强度、ADHD 与创造力的觉醒	10
2.1 intense 人格与 ADHD 特质	10
2.2 甄嬛传与 eureka 时刻	10
2.3 Paper、Research 与 Science 的三层区分	11
2.4 本章小结	13
3 从算法到基础设施：AI 浪潮中的转型	13
3.1 谷歌实习与 LLM 的初次冲击	13
3.2 SGLang 的诞生与开源之路	14
3.3 xAI：自由、支持与成长的阵痛	16
3.4 本章小结	17
4 创业与 RadixArk：Infra First 的愿景	17
4.1 离开 xAI：社区需求的紧迫与创业决心	17
4.2 LLM Infra 全景解读	19
4.2.1 Infra 的完整版图	19
4.2.2 Post-training 与 RL：扇出点	19
4.2.3 Inference：贴近用户的末端	20
4.2.4 Inference 市场的独特格局	20
4.3 RadixAttention 与核心技术	20
4.3.1 从 KV Cache 说起	20
4.3.2 RadixAttention 的核心思想	20
4.3.3 研究方法论：一次性看见，一件件做	21
4.4 Infra 的美感与浪漫	21
4.4.1 Taste：不仅是 End Goal	21
4.4.2 Infra 不是 Support 角色	22
4.4.3 RadixArk 的反转：Job 可以 Pause	22
4.4.4 团队文化：Focus, Humble, 精益求精	23
4.5 Sand Hill Road：融资的规则与人性	23

4.5.1	Professor 与 Founder: 都只是 Approach	23
4.5.2	融资的曲折与 First Principles	24
4.5.3	NVIDIA、AMD、Intel 的罕见集体投资	24
4.6	本章小结	24
5	开源信仰、平权理想与 AI 的未来	25
5.1	开源信仰的根源: 互联网养大的孩子	25
5.2	开源生态的变与不变	26
5.3	去中心化愿景与 AI 的未来	27
5.4	LMSYS: 孵化平等机会的平台	27
5.5	性别与科技: 微妙但持续的不对称	28
5.6	本章小结	30
6	总结与延伸	30
6.1	世间的美好: 波折之后的正反馈	30
6.2	逻辑自洽与情感割裂	31
6.3	核心思想提炼与延伸思考	31
6.4	拓展阅读	32

1 从江西到硅谷：一个基建工程师的成长之路

1.1 嘉宾介绍与背景概览

在 AI 基础设施领域，有一类人不满足于在现有框架上做增量优化，而是试图从底层重新定义“基建”本身的形态。盛颖（Ying Sheng）正是这样一位工程师与研究者。她的履历横跨算法理论、形式化验证与大模型系统三个看似跨度极大的领域，却在“基础设施”这条主线上找到了一致的内在逻辑。

盛颖本科毕业于上海交通大学 ACM 班——中国计算机竞赛领域最顶尖的荣誉项目之一。此后赴美，在哥伦比亚大学获得计算机科学硕士学位，又在斯坦福大学师从 Clark Barrett 教授完成博士学位，研究方向从形式化验证 (Formal Verification) 逐步转向大模型系统。博士期间，她成为 LMSYS 开源社区的核心成员，参与推动了包括 LM Arena 在内的一系列具有行业影响力的项目，并创办了开源推理引擎 SGLang。




图 1: 盛颖的 LinkedIn 主页概览¹

毕业后，盛颖加入 xAI，共同领导 Grok 大模型的推理团队，将开源研究的理念带入全球最受瞩目的大模型工程实践。随后，她从 SGLang 开源生态中孵化出创业公司 RadixArk，致力于将只有少数科技巨头才能拥有的前沿 AI 基础设施，变成整个行业都可以使用的开放技术底座。

RadixArk：一亿美金种子轮的信号

RadixArk 创立之初便完成了 1 亿美元的种子轮融资，投资方几乎集齐了硅谷所有的算力巨头——NVIDIA、AMD、Intel 等芯片厂商罕见地同时出现在同一家初创公司的投资名单上。这一融资阵容本身就是一个强烈信号：在 AI Infra 层面，硬件巨头们需要一个中立的、开源的软件层来释放算力的全部潜力，而 RadixArk 正是他们认定的那个角色。采访时公司已有 40 余人，且扩张速度超出创始人自身预期。

在采访开场的快节奏金句预览中，盛颖抛出了几个贯穿全片的核心判断，它们构成了理解她整段人生选择的关键坐标：

¹ 视频画面时间区间：00:00:10–00:00:14。

核心金句预览（开场快剪）

盛颖 (00:01:07): “我想要 *build* 的未来，就是一个跟强力 *AI* 共同的未来。”

盛颖 (00:01:14): “以模型为目标的这些公司，在 *Infra* 的美感上有所妥协。我跟 *Infra* 之间是一种浪漫的关系——我觉得 *Infra* 不是一个 *support* 角色，*Infra* 本身在我眼中就是产品。”

盛颖 (00:01:22): “我是个必须 *intense* 的人……*ADHD* 不是一个缺陷，它是一个特点。我突然知道我应该顺着我的天赋去做事情，你一旦悟到了这个之后，很多事情就迎刃而解。”

盛颖 (00:01:44): “世界上存在那么纯粹那么好的导师，存在那么好的投资人……那些好的人都存在，但是你要非常相信它。你要相信到——你身边没有这样的人，你还相信它。然后有一天，跟你一样相信的人，他有一天会跟你相遇。”

这些金句并非孤立的鸡汤，而是盛颖在经历了求学低谷、职业转型、创业抉择之后沉淀出的认知框架。接下来的几个小节将逐一展开这些判断背后的真实故事。

1.2 求学之路：从竞赛少女到斯坦福博士

1.2.1 从江西到上海交大 ACM 班

盛颖的技术之路始于江西。她在访谈中多次提到，从江西到上海交大读本科时经历了一次强烈的“文化冲击”（*cultural shock*）——身边的同学对职业发展、人生规划有着更系统的认知，而她自认处于一种“无知状态”。这种朴素的自我评价与后来的成就形成鲜明反差，但恰恰揭示了一个重要事实：顶尖人才的早期轨迹并不总是光鲜的，很多关键转折来自偶然与直觉，而非精心规划。

上海交大 ACM 班是中国计算机竞赛领域的顶级培养平台，聚集了全国最优秀的编程竞赛选手。盛颖进入这个环境，为后来的算法功底和系统思维奠定了坚实基础。

1.2.2 哥伦比亚大学：纽约的“放松式冲击”

本科毕业后，盛颖的申请过程并不顺利。她最初甚至没有拿到美国大学的 offer，已经接受了香港中文大学的 PhD offer 并签署了君子协议。然而就在 deadline 过后的第二天，哥伦比亚大学发来了一个“很普通的”硕士 offer。面对这个意外的选择，她给父亲打了一通电话：

一通改变轨迹的电话

盛颖 (00:04:15): “我还跟我爸打电话说，前面的 *PhD offer* 能不能毁？我还需要交一笔违约金，但是我想出去看看。我还犹豫了一下，然后给我爸打了通电话。但我爸非常快，就是一分钟就说‘好你去’。”

这个决定看似草率，却改变了她此后的整条人生轨迹。在哥大期间，盛颖体验到了纽约独特的包容性文化——她将其描述为一种“不需要被注视，也不需要注视别人”的自由状态。




图 2: 盛颖的教育背景概览²

在学术上，盛颖最初并没有读博的计划。第一学期选修了计算复杂性课程后，她被理论研究的纯粹之美所吸引，结交了一批做理论的博士生朋友，开始自发地寻找可以研究的问题。这段经历让她产生了一种极致的心流体验——她回忆起一次去普林斯顿参加 workshop 的经历：

普林斯顿的”虚无之美”

盛颖 (00:06:29): ”进到普林斯顿校园那个环境里面，我就突然觉得与世无争……你人世间的很多大家所在乎的东西，你平时去挣扎争夺的东西，都非常的没有意义。”

主持人: ”那什么是重要的？”

盛颖 (00:07:05): ”就是什么都不重要是重要的。就是一种虚无——你觉得虚无才是它真实的东西。只有真实是重要的。数学在那个环境下就会显得特别优美，因为它是确定性的，而且是绝对化的。”

这段描述虽然高度理想化，但它解释了盛颖选择继续深造的内在驱动力——不是为了职业回报，而是一种对纯粹智识体验的渴望。

1.2.3 斯坦福 PhD：轮转困境与导师危机

然而，到了斯坦福之后，那种纯粹的心流状态消失了。盛颖坦率地承认，斯坦福前几年的经历”并不顺利”。

斯坦福的 PhD 项目采用 rotation 制度——学生需要在多个导师的实验室轮转，找到匹配后才能确定此后五年的研究方向。盛颖在前几轮轮转中都没有找到合适的导师。有时是她对导师的问题不够感兴趣，有时是双方没有完全”match 上”。直到第四轮，她才与 Clark Barrett 教授匹配，进入了形式化验证这一全新领域。

²视频画面时间区间：00:00:13–00:00:17。

关于 PhD 轮转的常见误解

很多人以为顶尖 PhD 项目的学生从入学第一天就目标清晰、导师匹配完美。盛颖的经历恰恰说明了相反的情况——即使是最终取得突出成果的研究者，早期也可能经历方向迷茫、导师不合、被动选择等困境。轮转制度的设计初衷正是为了缓解这种不确定性，但它本身也带来了焦虑。盛颖进入形式化验证方向在很大程度上是”被动的”——”因为我要读这个 PhD，所以我才需要不停地去做研究、产出论文”。真正的热爱是在做的过程中慢慢培养出来的。

1.2.4 形式化验证：从被动进入到发现美感

尽管进入形式化验证领域带有被动色彩，盛颖的产出却极为高效。2020 年，她在该领域发表的第一篇论文就获得了 IJCAR 最佳论文奖——而她当时对领域的认知还是”完全小白的状态”，甚至不知道什么样的论文才算好。




图 3: 盛颖的 Google Scholar 论文列表³

她的研究聚焦于 SMT Solver (Satisfiability Modulo Theories 求解器) 的优化——这是形式化验证的核心工具。简单来说，形式化验证的目标是将人写的代码映射到底层的数学逻辑（如一阶逻辑），然后从数学角度证明代码是否满足特定性质。

³视频画面时间区间：00:00:18–00:00:22。



图 4: 形式化验证 (Formal Verification) 知识卡片⁴

形式化验证与 SMT Solver

形式化验证是用数学方法证明程序正确性的技术。其核心流程是：(1) 为程序定义一套 **Specification** (规约)，描述代码应满足的前置条件 (precondition)、不变量 (invariant) 和后置条件 (postcondition)；(2) 将代码和规约映射到数学逻辑公式；(3) 用 **SMT Solver** 自动推理这些公式，判断代码是否真正满足规约。

盛颖的研究重点在于 SMT Solver 本身的优化——不仅涉及效率 (efficiency)，还涉及如何定义合适的语义空间 (semantic space) 来表达代码的行为。她提到了一个深刻的洞察：程序语言设计存在一个根本性的 trade-off——接近数学的语言更容易被形式化验证，接近硬件的语言则更灵活高效。这两端很难兼得。

1.2.5 COVID 低谷与”教科书般完美的导师”

然而，就在第一篇论文获奖之后，盛颖陷入了长达近一年的抑郁状态。COVID 疫情的到来切断了正常的学术交流，她找不到下一个让自己感到兴奋的问题。这段经历中，导师 Clark Barrett 的角色至关重要。

导师 Clark Barrett 的支持

盛颖 (00:12:18): ”我遇到了非常好的导师。Clark 非常 *supportive*。他完全理解说我要调整好这个状态。他只关心我是不是有一个好的精神状态，只关心我是不是能够走出来。他没有给我施加任何我 need 继续产出论文或者做什么事情的 pressure。他说那我可以去上一些课，做一下 TA，做一些很轻量级的事情。我甚至回国待了半年——一个疗愈期。我没有产出论文，但 Clark 从来没有断过我的经费。”

这段经历深刻地塑造了盛颖对”好导师”的定义——不是在学术产出上施压，而是在学生最脆弱的时候给予无条件的支持和空间。她后来将 Clark Barrett 称为”教科书般完美的导师”，这一评

⁴ 视频画面时间区间：00:09:28-00:09:32。

价在访谈中反复出现。

走出低谷后，盛颖完成了一篇关于 Sequencing 的论文，其中包含一个长达 20 多页的证明，来回修改了四五次，其中两次几乎全部推翻重写。Clark 本人也认为那篇论文的证明是他那一年的 highlight。这段“先崩溃、后重建”的经历，反而让盛颖真正理解了形式化验证的深层之美。

盛颖对研究节奏的真实描述

盛颖坦言，她在形式化领域发表的三篇论文分布在三年时间里，但每篇真正推动的时间其实只有三个月左右。每年都有大约九个月“不知道在做什么”——处于迷茫、寻找问题、甚至完全停滞的状态。外人看到的年度成果，实际上是最后一个季度的爆发。她强调，这并不是懒惰，而是一种“必须找到真正 exciting 的问题才能做好”的个人特质。她后来学会了接受这种节奏，而不是强迫自己去做不感兴趣的事。

最终，尽管在形式化验证领域取得了显著成果（包括 IJCAR 最佳论文奖、IJCAR 最佳论文提名、TACAS 最佳工具论文奖等），盛颖还是选择了转向 AI。原因很简单也很诚实：形式化验证“能够在现实中被应用的场景太少了”——验证一个程序的成本太高，而能验证的范围又太有限。她想“离世界更近一点”，做“更接近真实生活的东西”。这次转型，同样经历了近一年的空窗期。

1.3 Two Sigma：华尔街的半年体验

在盛颖的人生轨迹中，有一段容易被忽视但颇具启发性的插曲：哥伦比亚大学硕士毕业后、进入斯坦福 PhD 之前，她在华尔街对冲基金 Two Sigma 工作了大约半年。

1.3.1 动机：智识好奇与“体验驱动”的人生哲学

盛颖选择 Two Sigma 的动机非常纯粹——不是为了赚钱，而是出于对量化金融的智识好奇。当时量化基金圈的口碑是“里面的人很聪明，好多 PhD，学物理的、学数学的”。对于一个热爱智力挑战的年轻人来说，这种环境本身就是吸引力。

选择 Two Sigma 的真实理由

盛颖 (00:50:01)：“我喜欢做有挑战的、跟智商挑战的事情，所以它这个特点当时吸引我。那个时候我也就 21、22 岁，单纯地被智识吸引。我觉得这个事情我要是不体验的话，以后我会一直想着它。但是我又觉得金融不是我的人生追求——我又觉得天天在那玩钱没啥意思。”

盛颖 (00:51:59)：“（金融）不是 *priority*。我只想体验一下。我一开始就知道那不是我的 *priority*。体验还不错。”

这段话透露了盛颖做人生选择的一个重要模式：先满足好奇心，再做判断——而不是先判断“是否值得”再决定是否尝试。PhD 中间恰好有半年的 gap 期，于是她把这当作一次“体验式学习”。

1.3.2 Two Sigma 的组织文化：一个意外的参照系

盛颖对 Two Sigma 的评价出人意料地高。在她工作过的所有公司中，她将 Two Sigma 排在第二位——仅次于 xAI。

为什么一家对冲基金的 Infra 反而最“干净”？

盛颖的核心观察是：Two Sigma 虽然不是一家科技公司，但它的 Infra 环境是她经历过的所有公司中最“organized”（有序）的。她当时身处其中并没有特别的感觉，直到后来去了其他科技公司才意识到“原来其他地方这么乱”。

她将原因归结为 Two Sigma 的业务模式——量化交易的业务逻辑相对稳定，变动不多，因此团队能够投入大量精力做持续的 maintenance（维护），而不是不断追赶新需求。这种环境下的代码库和基础设施自然更加干净、稳定。这一洞察在她后来创立 RadixArk 时产生了回响——对 Infra 而言，“稳定的业务模式”比“激动人心的创新”更有利于产出高质量的基础设施。

此外，盛颖特别强调了 Two Sigma 当时的文化氛围：开放、协作、拥抱开源、拥抱新技术和人工智能。“所有人都只是在做事情”——没有多余的政治斗争或内耗。她在那里结交的朋友至今仍保持联系，有些继续留在量化领域，有些已经转向 AI 创业。

Two Sigma 简介

Two Sigma 是全球顶尖的量化对冲基金之一，总部位于纽约，以技术驱动的投资策略著称。与传统金融机构不同，Two Sigma 大量雇佣计算机科学、物理学、数学等领域的 PhD，用算法和数据科学方法进行投资决策。公司内部高度重视技术基础设施建设，并曾积极参与开源社区（如开源了 Beaker Notebook 等项目）。盛颖所经历的“Tech 对冲基金”文化，代表了华尔街中一种独特的、以工程师文化为核心的组织形态。

1.4 本章小结

本章梳理了盛颖从江西到硅谷的成长轨迹，其中有几个值得提炼的关键模式：

- 1. 非线性的成长路径：**盛颖的每一次重要转折——从港中文 PhD 到哥大硕士、从理论到形式化验证、从形式化验证到 AI——都不是精心规划的结果，而是在偶然机遇与内在直觉的交互中完成的。她的经历提醒我们，在快速变化的技术领域，“保留选项、保持开放”可能比“从一开始就选对方向”更重要。
- 2. 导师的关键作用：**Clark Barrett 在盛颖最低谷时期的无条件支持，展示了一种理想的导师-学生关系——不以产出为唯一衡量标准，而是为学生提供安全的探索空间。这种支持最终转化为更高质量的学术成果。
- 3. 接受自己的工作节奏：**盛颖对自己“九个月空窗、三个月爆发”的坦率描述，打破了关于高产研究者的刻板印象。她的核心洞察是：与其强迫自己适应外部节奏，不如学会“服从自己的特点”，在真正 exciting 的问题面前释放全部能量。
- 4. 体验式决策：**无论是选择哥大硕士还是 Two Sigma 实习，盛颖的决策逻辑都是“先体验，再判断”。这种模式在短期看可能不是最优的职业策略，但从长期看，它为她积累了独特的认知宽度和跨领域的参照系——而这恰恰是后来做 AI 基础设施创业的重要底层能力。
- 5. Infra 审美的早期萌芽：**Two Sigma 的“organized”文化给盛颖留下了深刻印象，也为她后来提出“Infra 本身就是产品”这一核心理念埋下了伏笔。

2 认识自己：强度、ADHD 与创造力的觉醒

2.1 intense 人格与 ADHD 特质

盛颖在访谈中反复出现一个关键词：intense。当主持人问她是否天生喜欢高强度的状态时，她的回答简洁而坚定：“我是个必须 intense 的人，从小就是这样。”这不是一种自我标榜，而是一种经过反复验证的自我认知。她描述自己即便在睡觉时也会不停做梦，梦境并非天马行空的片段，而是与工作和生活高度相关的延伸思考。换言之，她的大脑几乎没有真正“关机”的时刻。

这种特质有一个更精确的名字：ADHD（注意力缺陷多动障碍）。盛颖坦言自己经常看心理医生，并确认了 ADHD 的诊断。但她对这个标签的态度非常值得注意——她不把它当作疾病，而是当作一个“特点”。

ADHD：不是缺陷，是使用手册

盛颖 (19:34-20:01)：我以前不知道 ADHD 这个东西。有一天我慢慢了解到，深入理解之后，我发现好多东西都被解释了。它给我带来最大的帮助，是我通过理解它而理解了我自己，像是找到了怎么使用我自己的一把钥匙。

陈茜：突然知道了，手册有了。

盛颖：对，它是一个手册。我突然知道了，我不应该逆着我的天性去做事情，我应该顺着我的天性去做事情。

“手册”这个比喻极其精准。对很多人来说，了解自己的认知特点并不意味着把它“治好”，而是找到与之共存的方式。盛颖的 PhD 期间曾经历严重的抑郁，她将其归因为疫情期间环境的强制减速——一个需要 intense 刺激才能正常运转的大脑，被迫放进了一个 slow down 的世界里，精神健康便出了问题。

但 intense 并不等同于“必须很忙”。盛颖在哥伦比亚大学做数学研究时，每天可能只思考四个小时，其余时间都在打游戏。问题太难了，能做的就是等灵感来。关键不在于时间的密度，而在于认知的强度——大脑被某个问题抓住、进入心流状态，那种深度专注才是她真正需要的燃料。

ADHD 的两极化特征

ADHD 在盛颖身上表现为极端的双模式：当被某件事深深吸引时，她会进入高度心流状态——听不见别人叫名字，忘记时间，错过会议；当事物无法触发兴趣时，她完全无法集中注意力，“哪怕事情很重要，我也不会 focus”。这种两极化不是意志力问题，而是神经认知层面的运作方式。理解这一点，是她学会“顺着天性做事”的起点。

她进一步澄清了一个常见的误读。很多人以为她是“好胜心强”，但她说：“我不是真的很在乎输赢，但是我在乎那个 intense 的感觉。”游戏可以输，比赛也可以输，但那个过程中大脑被完全抓住、全力运转的体验，才是她真正追求的东西。这与心理学中“内在动机”的概念高度一致——驱动力来自活动本身的体验质量，而非外部奖惩。

2.2 甄嬛传与 eureka 时刻

盛颖在硕士期间的一个研究突破，来自一个极其不寻常的场景：看《甄嬛传》的时候。

她回忆说，当时自己在做数学理论研究，问题极难，能做的只有空想和等待。某天她看了一篇 paper 之后去看电视剧，看到中段的时候，那篇 paper 里的某个点突然“echo 出来”，她猛然意识到

那就是突破口。

看电视剧时的 phase transition

盛颖 (18:35–19:10): 其实我当时那个题目做解出来,就是在我看电视的时候想到的 idea。我看电视之前看了一篇 paper,然后我就看电视去了。看了中段的时候,不知道为什么那个 paper 里的东西突然回响,echo 出来。然后突然意识到,这个地方可能是一个解法突破点。那个就是关键点。那个是真的有一个 phase transition,就是一瞬间的事情。

陈茜: 你还记得是什么电视剧吗?

盛颖: 《甄嬛传》。我真的记得。

这个故事绝不仅仅是一个趣闻。它揭示了创造性思维的一个核心机制: **潜意识孵化** (incubation)。当大脑在有意识层面离开了问题,转去处理一个完全不相关的刺激(电视剧的情节),潜意识仍然在后台运行着对问题的搜索。而恰恰是因为表层注意力被占用、防御性思维放松了,深层的联想网络才更容易产生跨领域的连接。

这也与她的 ADHD 特质形成了一个有趣的闭环: 正因为她看电视时注意力也不会完全沉浸(她说自己经常需要回退重看, 30 分钟视频要看 40–50 分钟), 大脑始终保留着一部分带宽在处理其他信息流。对大多数人来说这是“分心”的缺陷,但在她的认知架构中,这恰恰成为了创造性突破的通道。

Theory 研究的特殊节奏

盛颖区分了理论研究(theory)与系统研究的本质差异。理论研究中,“有很多灵感你只能等它来,其实你没什么事情可做,你只能在那等”。这种等待不是懒惰,而是必要的认知酝酿期。很多重大数学突破都发生在散步、洗澡、或从事不相关活动的时候——大脑需要在非线性的联想模式下运转,而不是在线性的逻辑推演中死磕。

2.3 Paper、Research 与 Science 的三层区分

当主持人提到盛颖发表了大量论文并暗示这是“天才”的标志时,她给出了一个极为清醒的三层框架。这个框架不仅是对学术界的冷静观察,也是她对自身定位的诚实判断。

第一层: Paper. 发 paper 是一项可以被套路化的技能。盛颖直言:“发 paper 是有套路的。你只要掌握了这个规则,然后掌握了这个体系的规律,在同样的规律里面不停地产出,你就可以一直发很多 paper。”她将此类比为命题作文——框架是给定的,你套着框架去填充内容即可。一个根本不怎么懂 research 的人,也完全可以发出大量论文。

第二层: Research. 做 research 是一个职业,与做其他工作没有本质区别。一个 researcher 享受系统性地探索问题的过程,但产出的研究大多数“不 breakthrough、也不 key”——不意味着没有价值,只是并非在推动人类知识的边界。绝大多数教授也处于这一层。

第三层: Science. 真正的科学推动者,在盛颖的定义中是极少数人——“如果不是他,这个事情会很长时间才发生”。这批人在推动人类认知边界,不是在已有框架中产出,而是在创造新的框架本身。



图 5: 形式化验证领域的 Specification 概念示意⁵

Paper-Research-Science 三层模型

- **Paper**: 掌握体系规律后的规模化产出，本质是一种可习得的技能。
- **Research**: 系统性地探索问题，是一种职业选择，大多数研究者处于此层。
- **Science**: 推动人类知识边界，极少数人能做到——如果没有他们，那些发现会很久之后才出现。

这三层之间不是递进关系（做得多就能升级），而是本质类型的差异。很多人混淆了前两层，以为发很多 paper 就等于在做 research；也有人混淆了后两层，以为做了 researcher 就是科学家。

当被问到深度学习三巨头（Hinton、LeCun、Bengio）是否属于第三类时，盛颖的回答体现了她另一个突出的思维特质——对一手信息的执着：“我非常在乎一手信息，非常在乎 true seeking。我不想评价我没接触过的人。但既然他们的世俗成就这么高，他们应该是吧。”

关于天赋的问题，她的看法同样不落俗套。天赋不是“比别人聪明”，而是“当所有人都不觉得这件事伟大的时候，你还想做它”。她以自己做理论数学为例：周围的人并不觉得 theory 多伟大，赚的钱也很少，但她还是觉得有意思——那种与外部评价无关的内在驱动力，才是真正的天赋所在。

天赋的真正含义

盛颖 (23:22-24:31): 天分是指当外界不把研究当回事、不觉得研究是件伟大的事情的时候，你还想做它，那就是你的天分。我想做这件事情，是因为我希望跟别人无关，是因为我享受它本身。那个时候才是你真正的所谓兴趣和天分所在的时候。

⁵ 视频画面时间区间：00:10:00-00:10:30。

关于“天才”标签的常见误区

竞赛圈和学术圈常常用论文数量、获奖记录来标定“天才”。但盛颖指出，这混淆了“掌握套路的能力”与“推动边界的能力”。一个银牌选手未必是天才，一个高产作者也未必在做真正的 research。自我认知的关键不在于比较，而在于诚实地分辨：你做这件事，到底是因为它酷、因为铁饭碗，还是因为即使没有任何外部回报你依然想做？

2.4 本章小结

本章的核心是一个关于自我认知的故事。盛颖通过理解 ADHD 找到了“使用自己的手册”——不再逆着短板努力，而是顺着天性做事。她的创造力不来自刻意练习或持续高压，而来自 intense 的心流体验和潜意识的自由运转。而在对学术产出的冷静分类中 (Paper、Research、Science)，她给出了一个诚实的自我定位：“我只是一个 researcher，我不是那个科学家。”这种自知之明并非谦虚的修辞，而是对不同层次创造活动的结构性理解——知道自己在哪一层，才能真正在那一层做到最好。

3 从算法到基础设施：AI 浪潮中的转型

3.1 谷歌实习与 LLM 的初次冲击

2022 年暑假，盛颖进入 Google 实习，加入的团队是 AI for Code——一个位于 Google X（内部孵化项目）中的小组，全职约一二十人。这不是她的第一志愿：她本来想进纯 AI 方向的团队，但被拒了。AI for Code 之所以接纳她，是因为该岗位与 programming analysis（程序分析）有交叉，而这恰好是她在斯坦福做形式化验证时积累的背景。




图 6: 盛颖早期研究工作的学术发表截图⁶

进入团队后，她发现了一个令人震撼的事实：当时 AI for Code 领域的人们还在试图利用传统程序分析 (programming analysis) 的 technique 和 tools 来辅助 AI 写代码，但作为从程序分析领域过来的人，盛颖深知这些工具“非常无力”——它们完全帮不上忙。

⁶视频画面时间区间：00:11:30-00:12:00。

被 LLM 震撼的瞬间

盛颖 (28:27–29:42): AI 人的幻想说, 我是不是可以利用另外一个领域的工具、交叉学科的希望, 来更好解决这个问题。但我作为从另一个领域过来的人, 发现这个工具非常无力。相反我反而看到了大模型其实已经把传统领域里的技术都完全覆盖了。……AI 原来这么 powerful! 我发现根本就不需要什么显式的 reasoning。我是被 shock 到的那个人。

这段经历的时间点非常关键——2022 年夏天, ChatGPT 尚未发布, 但 Google 内部已经可以接触到 PaLM 和 Lambda 等大型语言模型。那位因声称“Lambda 有意识”而引发轩然大波的 Google 工程师, 正是同一时期的事件。盛颖指出, 虽然当时离全民爆发还有距离, 但圈内人已经能感受到 LLM 的巨大潜力——模型能生成一两百行代码, 尽管离真正的 production-level code generation 还有相当差距。

那个暑假, 团队非常激进——招了与全职等量的 intern, 让他们疯狂尝试不同方向。这种“广撒网”的策略本身就说明, 即便在 Google 内部, 人们也还在摸索 LLM 应用的边界在哪里。

2022 年: AI 变革的前夜

2022 年是一个微妙的时间节点。Google 的 PaLM 和内部的 Lambda 已经展示了大模型的潜力, 但 ChatGPT 要到当年 11 月底才发布。圈内人已经看到了方向, 但距离公众认知还有半年的时间差。盛颖恰好在这个窗口期进入了 AI 领域——不是作为 AI 原住民, 而是作为一个从形式化验证“跨界”过来、因此能以外部视角感受到冲击的人。这种“被 shock”的体验, 成为了她后续职业路径的转折点。

更深层的收获在于认知转变。盛颖发现自己更适合做 infra 而非算法: “做 infra 跟我的思维习惯更接近, 它是 co-reason 的、确定性的、基于数学的, 然后基于代码——数学和代码这两件事情我都很熟悉。”这不是一个随意的选择, 而是在尝试了算法方向之后的自然筛选——她在算法方向没有取得突出成功, 但在 infra 方向上成功了。又一次, 她选择了“顺着天性做事”。

从算法到 Infra 的认知跃迁

很多 AI 从业者在面对“算法还是系统”的选择时, 倾向于选择算法, 因为那里有更多的论文发表机会和学术声望。但盛颖的经历说明了一个反直觉的道理: infra 可以比算法更有 impact。当模型能力已经达到某个阈值之后, 真正的瓶颈往往不在“模型能不能做”, 而在“系统能不能让模型稳定、高效、大规模地做”。选择 infra 不是退而求其次, 而是找到了杠杆更大的位置。

3.2 SGLang 的诞生与开源之路

SGLang 的起源可以追溯到盛颖 PhD 最后两年的一系列研究工作。她在转向 AI 后, 集中精力做了 LLM inference 相关的多个项目——FlexGen 是第一个, 之后连续产出了 S-LoRA、S-Lion、Finance 等多个不同角度的 work。SGLang 则是这一系列研究的“收官之作”: 她希望把之前分散的、各自 local 的创新, 集大成为一个统一的推理引擎。



图 7: SGLang 开源项目的 GitHub 数据概览⁷

从一开始, SGLang 就不只是一篇论文的附属代码——它从立项之初就瞄准了 production ready, 目标是成为可以被广泛使用、大规模部署的推理引擎。这个定位本身就意味着, 她需要做大量”超出 research”的工作: 项目维护、社区运营、工程细节的琐事。

SGLang 与 vLLM 的关系是社区中常被讨论的话题。盛颖坦诚地还原了历史: 她最初自己在做 research, 后来听说 vLLM 项目的 idea 与她正在思考的方向类似, 于是被建议 merge 进 vLLM 项目。在她的视角中, ”我是被 merge 进了 vLLM 那个项目”。但 vLLM 在从论文转为开源项目后, 需要大量非 innovation 性质的维护工作, 盛颖当时没有太多参与, 而是继续做自己的其他 research。SGLang 是她在此基础上, 以一个新的 innovation 为起点, 构建的独立引擎。

SGLang vs vLLM: 差异与互学

盛颖 (32:10–32:51): SGLang 在更早期就进入了 scale up 的方向, 就是把大规模的 serving production——千卡级别、万卡级别甚至百万卡级别的 serving 做好了。vLLM 可能在社区覆盖、long tail 模型的支持上做得更早。所以大家的 focus 有所不同, 但现在去看的话, 两方又在互相学习, 在补齐短板。

SGLang 社区有一个独特的文化现象: 核心开发者们长期保持着”网友”关系——他们从未线下见过面, 甚至在线会议中也从不开摄像头。这不是刻意为之的匿名策略, 而是一种自然形成的协作模式。盛颖用一句话概括了她识别贡献者的方式: ”我只要看到有点代码, 我就知道你是谁。”代码风格成为了身份识别的标志, 比面孔更准确。

开源项目中的”网友社区”模式

SGLang 的核心开发团队形成了一种罕见的全远程、无面孔的协作模式。成员们通过代码质量和贡献频率建立信任, 而非通过社交关系或组织层级。这种模式在开源世界中虽不罕见 (Linux 早期也是如此), 但在 AI infra 这种需要高度协调的领域中仍然值得注意。它说明: 当参与者的内在动机足够强, 外在组织结构可以非常轻量。

⁷ 视频画面时间区间: 00:00:28–00:00:32。

3.3 xAI：自由、支持与成长的阵痛

盛颖 PhD 毕业后的第一站是 Databricks。她在那里待了约五个月，试图推广 SGLang，但并不成功。原因并非技术上的不适配，而是组织层面的摩擦：Databricks 已经是一家成熟公司，“做每件事情都需要充分的理由”；而她作为一个 new grad researcher，“还不会在一个成熟企业里 drive 一个比较大的 effort”。

转机来自 xAI。2024 年 10 月，盛颖加入了 Elon Musk 创办的 xAI，原因可以用两个词概括：support 和 freedom。

Support + Freedom

盛颖在择业时形成了一个清晰的判断框架：她需要同时获得两样东西——**support**（资源与组织支持）和 **freedom**（自由探索的空间）。很多机会只能给其中之一：大公司有 support 但缺 freedom，小团队有 freedom 但缺 support。xAI 在早期阶段恰好同时提供了两者，这是她最终加入的决定性因素。

盛颖和她的丈夫连敏一起加入 xAI，共同构建了 Grok 的 inference engine 和整个 infra 团队。她对早期 xAI 的评价极高——用她的话说，那是“我回忆最美好的一段时光”。当时 xAI 不到 100 人，团队氛围有几个突出特征：

- **没有 politics**——“我经历过那么多公司，xAI 是我第一次经历到一个 Team、一个公司里面完全没有任何 people game。”
- **人才密度高**——“个个都是人才，大家互相之间也都很 support、很 friendly、很 appreciate、很 humble。”
- **无边界文化**——Elon 设定了一种“没有边界的文化”，组与组之间没有壁垒，任何人都可以 touch 到任何事情，不会被限制在狭窄的 scope 里。
- **工程师文化主导**——没有过多的 people management 层级，做事非常直接。

这种环境给盛颖带来了全栈视角的成长。因为团队小、边界少，她能看到从 engine 到 product deployment、从 research evaluation 到 RL rollout 的所有 layer 如何协作。她将 xAI 的 intense 类比为健身：“你一定要很累了，感觉到痛了，你才会长肌肉。在那里待了一年，可能在外面是好几年才能拿到的成长。”

但美好的时光有其生命周期。盛颖用版本号来描述 xAI 的演变：0.0 版本（她加入前）像 Family 一样温暖；1.0 版本（她在的时期）开始有“生长痛”但大家仍然团结；后续的版本则经历了剧烈变化——co-founder 全部离开，或被解雇、或被裁员、或主动辞职。

从 startup 到大公司的阵痛

盛颖 (41:04–41:30)：我觉得 xAI 是没有过好那个阵痛期的——从很小的、很团结的 startup，变成一个需要靠体制来运转、而不是靠人来运转的大公司。这个过渡期的阵痛没有被很好地抚平，所以产生了这些巨大的变化。但有天它可能会找到一个新的 solution，只是可能是 another company 了。

她从这段经历中提炼出一个关键的组织管理洞察：小团队可以靠文化和人来运转，但规模扩大后，文化会变脆弱，个人能力也会变脆弱。能否成功 scale up，取决于 system（体系）是否建立起来——

最终要靠体系支撑，而不是靠人支撑。这个过渡”不是一个会自然发生的事情”，必须 intentionally thinking，否则”如果你不 pay attention，它就会 broken”。

创业公司的规模化陷阱

很多创业公司在早期享有”精英小队”的高效与纯粹，但在规模扩张时缺乏有意识的体系建设，导致文化稀释、核心团队流失。xAI 的案例是一个典型的教训：从人驱动到体系驱动的转变，不能在事后补救，必须在增长过程中主动设计。盛颖坦言自己也不知道正确答案，但她带走了一个 lesson——这个过程必须被刻意关注，不能 take it for granted。

值得注意的是，盛颖离开 xAI 并非因为不满，而是因为 SGLang 开源社区的需求增长到了一个节点——社区需要一个专门的公司来支撑其发展，而这件事只有她自己能做。她说：”如果不是因为这个原因，我是不可能选择离开 xAI 的。”这种决策方式再次体现了她在前一章所说的原则——不是在追逐外部机会，而是在回应自己认为”正确的事情”的召唤。

3.4 本章小结

本章追踪了盛颖从形式化验证到 AI infra 的转型轨迹。在 Google 实习期间，她被 LLM 的能力所震撼，同时清醒地认识到自己更适合 infra 而非算法——确定性的、基于数学和代码的系统思维，是她的认知优势所在。SGLang 从 PhD 收官之作发展为一个 production-ready 的开源推理引擎，其社区以”网友”式的代码驱动协作为特色。xAI 则给了她 support 与 freedom 并存的理想环境，让她在高强度中获得了全栈视角的快速成长。但组织的规模化阵痛也提供了一个深刻的 lesson：文化和人可以支撑小团队，但只有体系才能支撑大组织。从认识自己的大脑 (ADHD)，到认识自己的认知优势 (infra)，再到认识组织的运作规律 (人 vs 体系)，这是一条不断深化的自我认知之路。

4 创业与 RadixArk: Infra First 的愿景

4.1 离开 xAI: 社区需求的紧迫与创业决心

2025 年初，SGLang 在几波技术浪潮的推动下迅速获得了业界关注，大量企业的使用需求和合作请求涌向社区。然而，这个项目从诞生之初就是一个纯粹的社区项目——核心开发者都是网上认识的”网友”，有些共同工作了两年却从未见过面，开会从不开摄像头，彼此之间的默契是”我只要看到你的代码，我就知道你是谁”。



图 8: RadixArk 品牌标识⁸

这种浪漫的社区协作方式在项目规模尚小时运转良好，但当增长速度远超志愿者的承受能力时，问题就暴露了。所有人都有自己的全职工作，只能在晚上熬夜、中午加班、放假时写代码来为社区做贡献。盛颖用”低空飞过”来形容当时的交付状态——大家都很想 deliver，但已经被 stretch 到了极限，很多需求只能 borderline 完成，甚至无法成功交付。

”中空状态”的焦虑

盛颖将当时的状态描述为一种”中空”——外界对 SGLang 的期望不断升高，但背后实际上是空白的。社区有热情、有影响力，却缺乏全职团队来将这些转化为高质量的产品。她意识到，如果不尽快填补这个空白，社区就会让外界失望，而这种焦虑已经到了无法继续拖延的程度。

做出离开 xAI 的决定并非没有代价。盛颖在 xAI 工作了十个月，距离第一年 vesting 仅差两个月。但她说”等到七月份已经等了很久了”，五月份就已经受不了，到七月份实在无法再忍。对她而言，社区”两个月都等不了了”，而继续留在 xAI 意味着无法专注于 SGLang 的事情。

关于离开 xAI 的决断

主持人：从 xAI 出来应该放弃了很多赚钱上的回报？

盛颖：我确实是 one year cliff 的，我出来的时候是十个月，其实我只要再待两个月就可以拿到我第一年的 vesting。所以两个月都不能待？——对，等不了。等到七月份已经是等了很久了，如果不出来的话，可能这个社区就两个月都等不了了。

主持人：你觉得金钱对你有任何的重要性吗？

盛颖：有必须性没有重要性。它的必须性来自于有金钱可以让我解决很多事情更容易。我没有追逐过它，但你真说它不重要吧，我也没到那个程度。比如说我想创立这个公司，如果有钱我用不到钱、我自己还有钱，这是它对我的意义。

这段对话揭示了盛颖对金钱的独特态度：金钱是工具而非目标，它的价值在于让你有底气去做想做的事情。而她给自己设定的标准同样严苛——”如果我在 xAI 上班，我要对它有用，不然我不

⁸ 视频画面时间区间：00:00:43–00:00:47。

配在这个地方。”当心理状态已经无法让她对 xAI 产生 productive 的贡献时，继续留下反而是一种不诚实。

关于“等一等再走”的误区

很多人面对类似处境时会选择“再等等”——等 vesting 到手、等 bonus 发完、等合同到期。盛颖的选择说明了一个被忽视的成本：等待本身也是有代价的。当你的注意力已经完全转移到另一件事上，继续留在原地不仅是对自己的消耗，也是对当前雇主的不公平，更可能让真正重要的机会窗口关闭。

4.2 LLM Infra 全景解读

在讨论 RadixArk 的具体方向之前，盛颖为观众梳理了 LLM Infra 的完整图谱。这幅图谱远比大多数人想象的要广阔。

4.2.1 Infra 的完整版图

传统认知中，LLM Infra 主要包括三个模块：**训练**（Training）、**后训练**（Post-training）和**推理**（Inference）。但盛颖提出了一个关键洞见：

基座模型也是 Infra

在盛颖的框架中，基座模型本身也属于 Infra 的一部分。整个 foundation 包括：梯度（gradients）、代码库（codebase）、工具箱（toolbox）、沙盒环境（sandbox environment），以及中间状态的模型检查点（checkpoint）。它们共同构成一个工具箱，你可以在其中进行组合，不断产生适用于不同场景和目标的特异化模型。

这个视角的革命性在于：它把“做模型”和“做 Infra”之间的界限模糊了。模型不是 Infra 的对立面，模型是 Infra 提供的原料之一。RadixArk 要构建的，正是这样一个让用户能根据不同使用场景、不同数据形式、不同产品目标和不同 serving 目标，源源不断地产生最适合的模型的 foundation。

4.2.2 Post-training 与 RL：扇出点

在这个完整图谱中，post-training 和强化学习（RL）处于一个特殊的位置——它是整个 pipeline 的**扇出点**（fan-out point）。

为什么 Post-training 是扇出点？

在基座模型完成 pre-training 之后，到了 post-training 阶段，需求开始分化：

- AI 进入人类生活的各个方面，不同场景有不同需求
- 不再是“一个模型解决所有问题”，而是通过多次训练产生多个模型
- 多个企业都想要自己的定制模型
- 因此 post-training + RL 是一个天然的“开枝散叶”节点

这种扇出特性使得 post-training 特别适合 RadixArk 所追求的模式——提供一套通用的 Infra，让所有人都能在上面构建自己的模型。

4.2.3 Inference: 贴近用户的末端

Inference 处于整个 pipeline 的最末端：模型的架构和权重都已经确定，Inference 引擎需要做的是让模型在硬件上跑起来，通过 endpoint 让用户能够调用。这是最贴近用户的部分，也是 RadixArk 当前聚焦的起点之一。

盛颖的当前策略是先专注于 **Inference + RL** 这两个处于 pipeline 末端的模块，因为它们最直接面向市场需求。但她同时强调，RadixArk 的长远使命远不止于此——Inference 只是一个起点，而非终点。

4.2.4 Inference 市场的独特格局

Inference Provider 没有输家

盛颖对 inference 市场做出了一个敏锐的观察：在这个领域中，竞争者不断涌入，但**没有任何一家因为竞争对手的存在而萎缩**——所有玩家都在同步增长。Fireworks AI (估值 40 亿美元)、Together AI、Vistrion 等公司已经存在多年，每年还有新的 inference 公司层出不穷，但它们之间的关系更像是共同做大蛋糕，而非零和博弈。这说明 inference 市场的总需求仍在爆发性增长，远未达到饱和。

4.3 RadixAttention 与核心技术

4.3.1 从 KV Cache 说起

要理解 RadixAttention，首先需要理解 LLM 推理中的一个核心问题：**KV Cache 管理**。

当大语言模型处理一个请求时，它需要为输入的每一个 token 计算 Key 和 Value 向量，这些向量存储在显存中形成 KV Cache。随着上下文变长、并发请求增多，KV Cache 的显存占用会迅速膨胀，成为推理系统的关键瓶颈。

LLM Inference 的技术版图

盛颖在访谈中提到了多个相关技术方向，每个方向解决不同的子问题：

- **vLLM / PagedAttention**: 解决 KV Cache 的**内存管理**问题，用分页机制减少显存碎片
- **H2O**: 做 KV Cache 的**压缩**，减少存储量
- **S-LoRA**: 解决**多 adapter 并发**问题，让多个 LoRA 模型共享基座
- **SGLang / RadixAttention**: 解决**前缀缓存**问题，避免重复计算共享前缀的 KV Cache
- **Chatbot Arena**: 做模型**测评**，提供公平的比较平台

这些方向彼此关联但各有侧重，共同构成了 LLM serving 的完整技术栈。

4.3.2 RadixAttention 的核心思想

RadixAttention 的技术原理，用盛颖自己的话说“其实也比较简单”：

RadixAttention: 前缀复用的内存管理系统

当推理引擎收到大量请求时，如果这些请求之间存在**公共前缀**（比如多轮对话中共享的历史记录），那么就不需要重新计算公共前缀对应的 KV Cache，而是可以直接复用之前已经计算好的结果。RadixAttention 的实现分两步：

1. **建立索引**：用 Radix Tree（前缀树）对请求之间的前缀关系做 indexing
2. **映射存储**：将已计算的 KV Cache 存在 memory pool 中，并与前缀树的索引做 mapping

这样，当第二个请求与第一个请求共享前缀时，系统可以直接从 memory pool 中取出已有的 KV Cache，省去重复计算。

前缀复用的场景远比想象中普遍。盛颖指出，随着 agentic 场景的出现，几乎所有复杂应用都会涉及多轮对话，而多轮对话天然地要复用前面对话的 history——这意味着前缀共享”大量存在于几乎所有的场景里”。实际上，SGLang 最初设计时就是以 agent 为入口的，当时甚至设计了一个前端语言（structured generation language），目的是构建人与 AI 之间交互的 interface。

4.3.3 研究方法论：一次性看见，一件件做

当被问到面对如此多的技术方向，是预先规划好 road map 还是逐步发现问题时，盛颖的回答非常干脆：

Infra 研究方法论

主持人：你是有一个很完整的 road map 说这些东西都要一起解决，还是一步一步慢慢解决？

盛颖：我觉得是一次性看见的。短时间内一下看见很多问题，但你做的时候你得一件一件做。Idea 肯定是跑得比手要快的，也不是我一个人看见，很多人都看见。

主持人：在解决这些问题的时候，有哪个点是最难的？

盛颖：我觉得没有哪个点是难的。就是去做掉就可以了。

主持人：那你的优先级是怎么排序的？

盛颖：哪一个是最大的 bottleneck，要先解决最大的 bottleneck。也有些是 dependent，比方说你要先解决 memory 的 KV Cache 管理问题，然后你才能解决 prefix caching 的问题。

这段对话展示了一种极其务实的研究方法论：视野要广（一次性看见全局），行动要聚焦（一件件做掉），排序要理性（最大瓶颈优先），并且要尊重技术之间的依赖关系。

4.4 Infra 的美感与浪漫

如果说前面的内容展示了盛颖作为技术架构师的理性一面，这一节则揭示了她与 Infra 之间深层的情感联结——她用了一个很少有人会在谈论基础设施时会用的词：**浪漫**。

4.4.1 Taste: 不仅是 End Goal

盛颖的联合创始人曾提到，做 Infra 的人需要的 taste 和做 pre-training research 的人不一样。盛颖的看法略有不同——她认为本质可能是相通的，但她对 taste 给出了一个精确的定义：

Taste 的定义：End Goal 之外的东西

如果你追求的仅仅是 end goal（结果），那还不在于 taste 的维度上。Taste 意味着你关注的不仅仅是 end goal，还有达成 end goal 的方式。你的系统不仅能跑，你还知道它是如何跑起来的——它是以一个 well-designed 的形态跑起来的，还是以豆腐渣工程跑起来的？它们可能有同样的 end goal，但有 taste 的人在乎的是：达到目标的路径本身是否优美。

这个区分在软件工程中意义深远。两段代码可能产生完全相同的输出，但一段结构清晰、抽象合理、易于扩展，另一段则是 hacky 的临时方案。在压力下，大多数人会选择后者；有 taste 的人则坚持前者，因为他们知道短期的“能跑就行”会在长期累积为巨大的技术债务。

4.4.2 Infra 不是 Support 角色

被低估的 Infra 人

在以模型为目标的公司中（无论是 OpenAI、xAI 还是其他 AI 大厂），Infra 团队长期处于被 underestimated 的状态。他们被迫不停地 support 其他 component：support researcher 使用 Infra 工具跑实验、support product 团队让产品运行得又稳又快。Infra 在这些公司的功能层面受到追求，但在美感层面却被迫妥协——因为 deadline 和 benchmark 分数永远比代码优雅更“紧急”。

盛颖对此的反击是彻底的：

Infra 即产品

盛颖：以我跟 Infra 之间的浪漫的关系，我觉得 Infra 它不是一个 support 的角色。Infra 本身在我眼中就是产品。你在推一个产品的时候，你会想这个产品不是只有功能，你会想它美，你希望它好看好用、被人喜欢、击中用户的痛点、击中人性。但是没有人会说“我希望 Infra 击中人性”——可是从我的视角看，Infra 也是击中人性的。它只是没有直接到用户、没有那么直接的联系，但实际上它产生了深远影响，是从底层就开始往上传递的。

将 Infra 视为产品而非 support 角色，这不仅仅是一种情怀——它直接影响了 RadixArk 的组织设计和优先级排列。

4.4.3 RadixArk 的反转：Job 可以 Pause

在大多数 AI 公司里，training job 是最高优先级——一切为 training job 让路，Infra 团队需要 24/7 on-call 确保 job 不中断。RadixArk 把这个逻辑完全反转了：

RadixArk 的优先级反转

在 RadixArk，training job 可以 pause。当 job 遇到问题时，团队的 focus 不是打一个 patch 让 job 赶紧继续跑，而是把问题 systematically 解决。刷 benchmark 分数也不着急——“benchmark 不是第一优先级”。真正的 source of urgency 是：当你的 job 不能被正常迭代时，这个问题本身应该怎样从深层次去解决它。

这种做法在短期内看似“慢”，但它避免了 Infra 领域最常见的恶性循环：patch 叠加 patch，直到系统变成一座没人敢碰的技术债务大山。盛颖追求的是一种“先慢后快”的路径——用更多时间

做对的事情，换取系统长期的稳定性和可扩展性。

4.4.4 团队文化：Focus, Humble, 精益求精

当被问到 RadixArk 的企业文化时，盛颖用了几个简洁的关键词：**Focus**（专注）、**Humble**（谦逊）、**精益求精**。她希望 RadixArk 的每一个人都是”对自己特别挑剔的人，对自己的作品特别挑剔的人”。这种对极高审美标准的追求，与她关于 taste 和 Infra 之美的论述一脉相承——不是做出能跑的东西就够了，而是要把事情做 **solid**。

4.5 Sand Hill Road：融资的规则与人性

4.5.1 Professor 与 Founder：都只是 Approach

从学术界到创业界的身份转变，在很多人看来是一个巨大的跨越。但盛颖的理解截然不同：

身份只是手段

盛颖：我觉得我一直都只想我要做什么事情。能够借用的身份也好、资源也好，当时觉得什么是最好的选择我就会做什么选择，但它们都只有一个目的——我要做我想做的那件事情。两年前 professor 是一条路，两年后 professor 这条路走不通，我就开始开公司创业。不管是做 professor 还是开公司，它都只是 approach。我没有想过这个身份本身意味着什么，我不是很在乎那个身份。



图 9: NVIDIA 与 RadixArk 合作⁹

这种将身份视为工具而非标签的心态，让她能够以极低的心理成本在不同角色之间切换。当 professor 的路走不通时，她没有纠结于”学术身份的失去”，而是直接转向下一个能实现目标的 approach。

⁹视频画面时间区间：00:00:58-00:01:02。

4.5.2 融资的曲折与 First Principles

盛颖坦言融资过程“挺曲折的”，但没有展开细节。更有意思的是她学习 VC 世界的方式——依然是她一贯的 first principle thinking：

不同体系，相同人性

Sand Hill Road（硅谷风投聚集地）有一套自己的游戏规则，与学术界完全不同——利益结构不同、评判标准不同、做事方式不同。但盛颖认为，归根结底所有体系之下**还是人，还是人性**。当你进入一个新体系时，你需要学习的是这个体系怎么运转、各种利益点如何平衡，但如果你以人性作为推理基点，对整个体系的理解”还是可以被推理出来”。

她进一步提出了一个精辟的观察：

关于”套路”

主持人：就像写 paper 一样，它是有套路的？

盛颖：你学到了这个套路，那其实你很快。所有 average 的东西都是有套路的，所有 common 的事情都是有套路的。

这句话的深层含义是：套路能帮你达到”平均水平”，但真正出众的表现来自于套路之上的东西——对人性的理解、对事物本质的把握、以及你要传达的东西本身的真实价值。

4.5.3 NVIDIA、AMD、Intel 的罕见集体投资

RadixArk 的种子轮融资结果非常亮眼：NVIDIA、AMD、Intel 这三大半导体公司罕见地集体投资了同一家创业公司。当被问到”他们为什么投你们”时，盛颖的回答很诚实——”我也很想问投资人这个问题”。

但她也给出了自己的理解：RadixArk 是在这个赛道里”跑出速度的玩家”，让投资人可以看到未来。更重要的是，RadixArk 能够 **enable** 其他 AI 公司和想要进入 AI 领域的企业——帮助它们获得制造 AI 的能力、接近 AI 并利用 AI 创造更多价值。

早期投资的逻辑

盛颖对投资逻辑有一个清晰的阶段划分：

- **早期投资（种子轮）：**投资人看的是**人和事**——团队的能力、愿景的可信度、技术的独特性
- **后期投资（A 轮、B 轮之后）：**投资人看的是**数字和业绩**——收入增长、市场份额、盈利前景

RadixArk 的种子轮因为有核心技术（SGLang 和 RadixAttention）的支撑，投资人是”人和事一起看的”。

4.6 本章小结

本章记录了盛颖从 xAI 工程师到 RadixArk 创始人的转变过程，以及她对 LLM Infra 领域的深刻理解。几个核心主题贯穿全章：

1. **社区驱动的创业动机**：不是为了融资或财富，而是因为社区的需求已经到了”两个月都等不了”的紧迫程度，志愿者模式已经无法支撑项目的增长。
2. **Infra 的完整图谱**：LLM Infra 远不止”推理引擎”——它涵盖训练、后训练、推理，甚至基座模型本身也是 Infra 的一部分。Post-training 和 RL 是 pipeline 中的天然扇出点，而 Inference 是最贴近用户的末端。
3. **RadixAttention 的技术核心**：通过 Radix Tree 对请求间的公共前缀建立索引，复用已计算的 KV Cache，避免重复计算。这项技术在 agentic 时代尤为重要，因为多轮对话天然产生大量前缀共享。
4. **Infra First 的文化宣言**：Infra 不是 support 角色，Infra 本身就是产品。有 taste 意味着不仅追求 end goal，还要追求达成目标的路径之美。Training job 可以 pause，但 Infra 问题必须从根本上解决。
5. **融资与身份**：Professor 和 Founder 都只是 approach，身份不重要，重要的是你要做的事情。不同体系有不同规则，但底层都是人性。早期投资看人和事，后期看数字和业绩。

盛颖用”浪漫”来形容她与 Infra 的关系，这或许是本章最深刻的注脚：在一个所有人都在追逐模型 benchmark 和产品上线速度的行业里，她选择退后一步，把目光放在那个支撑一切的地基上——不仅要让它稳固，还要让它美。

5 开源信仰、平权理想与 AI 的未来

这一章从技术讨论转向价值观与社会关怀。盛颖在访谈的最后阶段卸下了工程师的分析框架，以第一人称讲述了三件深层驱动力：开源文化如何塑造了她的世界观，AI 的去中心化为什么不只是商业策略而是人类公平的前提条件，以及性别不对称如何在科技行业中以一种”微妙到你觉得它不是个事”的方式持续运作。这些话题彼此交织，最终收束为一个核心命题——**平等不是口号，而是让所有人在 AI 时代共存的结构性的前提**。

5.1 开源信仰的根源：互联网养大的孩子

盛颖对开源的态度，不是一种后天习得的立场，而是成长环境自然形成的本能。她出生在江西，一个中部省份，教育资源在全国范围内并不突出。她回忆自己少年时学编程的经历：没有系统教材，计算机竞赛也不是当时的热门赛道，市面上能找到的资源极为稀少。她的学习几乎完全依赖互联网——CSDN 上别人随手贴出的帖子、Online Judge 网站上的题目和解答代码。

盛颖谈开源的起源（约 01:21:30）

盛颖：我是被互联网上不知道世界上在哪里的人给养大的。就是我是被他们教会的。我至今也不知道他们是谁，当时我也不知道他们是谁，我只是过去把代码拿走了，回家研究。

盛颖：所以 sharing、open 的这个文化，它对我来说是一个……就像我生活的空气一样存在。我也没有觉得我在刻意追逐它。你有一个 idea，你做了一件事情，你不分享出来，那才觉得奇怪。

这段话揭示了一个常被忽视的事实：很多开源信仰者并不是在读了某本书或听了某场演讲后”皈依”开源的。他们从小就在开源的生态中被滋养，分享是他们认识世界的默认方式。盛颖用了一

个精确的比喻——空气。你不会刻意感谢空气的存在，但没有它你无法生存。对她来说，不分享才是反常的行为。

开源的自然状态

开源文化的最深层根基，不是意识形态，而是**受惠者的本能回馈**。那些在信息匮乏环境中靠匿名分享者的代码和文章成长起来的人，天然地把“开放”视为理所应当。这种信仰的力量在于它不需要论证——它是生活经验本身。

5.2 开源生态的变与不变

主持人陈茜随后问到开源社区近年来发生了什么变化。盛颖的回答非常平衡，既看到积极面，也指出了隐忧。

好的变化：越来越多人追求开源、相信开源的价值。这种趋势不仅体现在开发者的 mindset 上，也体现在资本对开源的认可上——两者都在上升。

不好的变化：随着开源的声望上升，开始有“不那么纯粹的东西”掺杂进来。盛颖用了一个尖锐的表述——

盛颖谈开源生态的隐忧（约 01:22:50）

盛颖：开源里面混进了一些功利主义者。这些功利主义者的存在，使得那些本来不是功利主义的人，分不清楚开源里面的成分，哪些是纯粹的，哪些是不纯粹的。他们的影响不仅仅是他们自己。

这段话指出了一个问题：功利主义者对开源的损害，不只是他们自身行为的问题，更在于他们的存在**污染了整个生态的信任基础**。当纯粹的贡献者开始怀疑“别人是不是也有 ulterior motive”时，社区的协作效率和精神凝聚力都会下降。

功利主义对开源的二次伤害

功利主义者混入开源社区的最大危害，不是他们自身的投机行为，而是他们让真正的信仰者产生怀疑。当一个生态开始“分不清楚哪些是纯粹的”，信任成本就会指数级上升，协作意愿就会下降。这是一种传染性的损害。

关于开源与闭源 AI 的走向，盛颖明确表示两者将长期共存。她既不站在“一切都应该开源”的极端，也不接受“AI 应该被一小批人垄断”的另一极端。她的判断基于对人性的清醒认知：

盛颖谈开源与闭源的共存（约 01:23:30）

盛颖：我也不觉得所有东西都应该开源。因为你不能没有规则，你也不能没有界限。完全的开放开源，如果没有掺杂太多可套利的空间，它可以是美好的。但你一旦把它完全打开的话，人性的恶意会被放大。

盛颖：两种 argument 都是正确的。我确实也不觉得 AI 应该完全展现在所有人面前，它确实有 risk。我也不站在 AI 应该完全被握在一小批人手上那一侧。

这种立场体现了一种成熟的现实主义：承认开源的美好理想，同时不回避“人性的恶意会被放大”这一事实。她不是开源的狂热布道者，而是一个深知其价值和边界的实践者。

5.3 去中心化愿景与 AI 的未来

盛颖进一步澄清了 RadixArk 的定位：它**不是纯粹为开源服务的**。RadixArk 也为闭源模型提供服务，但其核心主张是”去中心化”——闭源可以存在，但不应该把一切集中在少数玩家手中。

RadixArk 的去中心化逻辑

RadixArk 的目标不是消灭闭源，而是**提供工具让每个人都拥有制造属于自己的 AI 的能力**。开源与闭源共存，但最好的闭源模型不应该被少数人垄断。去中心化的核心是：你制造出来的 AI 属于你自己。

主持人提到 Anthropic CEO Dario Amodei 呼吁所有人停止 AI 研究，但附加条件是”大家都停止了，我才停止”。盛颖对此的判断非常直接：这件事不可能发生，因为它违背人性。在没有一个全知全能的”上帝”来安排所有人按部就班的情况下，一定会有人”起义”。

对于 AI 的未来走向，盛颖给出了分层判断：

近期（可预见的未来）：AI 还没有强到能完全控制和威胁人类。在这个阶段，AI 会在生产力层面取代人类的一些功能（”功能性的强”），但不能完全取代人。这个变革带来的社会动荡是巨大的，堪比甚至超过历史上的工业革命，但仍在”你可以理解的范畴”内。

远期（如果 AI 真的能 dominate 人类）：人类无法通过”呼吁所有人停下来”来阻止这一天的到来。

盛颖谈 AI 的终极路径（约 01:26:45）

盛颖：你阻止它的方式一定是发明、发现另一条路径，使得你允许 AI 继续前进，而人类还不会输。

盛颖：你先要让所有的人类平等共处，然后你才能再寻找一个人类与 AI 共存的路径。

这个论证的逻辑链条极为清晰：如果 AI 的进化不可阻挡，那么人类唯一的出路不是叫停 AI，而是找到一条让 AI 与人类共存的新路径。而寻找这条路径的**前提**是人类自身先实现平等——因为只有当所有人都能接触到最好的 AI、都在同一个竞争起点上，人类才能作为一个整体去面对 AI 带来的挑战。AI 平权不是一个道德口号，而是人类生存策略的结构性基础。

从 AI 平权到人类生存

盛颖的推理路径可以总结为三步：（1）AI 的进化不可能被人为叫停；（2）人类需要发明一条与强 AI 共存的新路径；（3）发明这条路径的前提是人类内部先实现 AI 资源的平等分配。因此，”让所有人拥有制造 AI 的能力”不仅是 RadixArk 的商业愿景，更是一个关乎人类整体命运的战略选择。

5.4 LMSYS：孵化平等机会的平台

LMSYS 是盛颖与连敏（Lianmin Zheng）共同创立的非营利组织。虽然目前它是一个大家 part-time 参与的机构，但盛颖对它的定位极其严肃。

盛颖谈 LMSYS（约 01:28:15）

盛颖：如果说 RadixArk 有一天不走到底的话，LMSYS 是那个我终身会做的事。

LMSYS 与 RadixArk 共享同一个核心价值：**平等和平权**。但 LMSYS 的平权是具体的、可操作的——它致力于孵化优秀人才的项目，即便这些人没有充分的背景、没有充分的后台、没有充分的 branding。更重要的是，LMSYS 保护这些尚未 establish 的开发者对项目的掌控权，确保 credit 真正分配给做事的人。

盛颖用自己的亲身经历来说明为什么这件事重要。她经历过低谷期，也经历过高光期，深刻感受到同一个人做同样质量的工作，在不同阶段获得的认可天差地别：

盛颖谈学术认可的不公平（约 01:28:50）

盛颖：可能同样是我，同样做了一件事情。我在高昂的时期做的那件事情，非常容易被大家关注到、被大家记住，甚至被大家夸大。但是我在低谷时期做的事情，有些也不错，但是其实你就很难被大家所看见或者被大家认可。

盛颖：虽然我是获益者，但是当我是获益者的时候，我终于有力量把这个事情往外推动一点。

LM Arena（现在广为人知的大模型排行榜）最初就是 LMSYS 框架下的一个“fun project”。盛颖和团队觉得这个事情挺有意思就做了，意外获得了大量关注。后来她们把这个项目交给了韦琳的团队，由新团队将其扩展到商业级别的规模。这个过程本身就是 LMSYS 价值观的体现：孵化、扶持、然后让真正运营它的人拥有掌控权。

LMSYS 的核心使命

LMSYS 的平权不是抽象的价值宣言，而是具体的制度设计：（1）孵化没有背景和 branding 的优秀人才的项目；（2）保护未 establish 的开发者对项目的掌控权；（3）确保 credit 分配给真正做事的人。它试图修正一个结构性偏差——同样质量的工作，不应该因为做它的人处于高光期还是低谷期而获得截然不同的认可。

5.5 性别与科技：微妙但持续的不对称

这是整场访谈中最私人、也最有力量段落之一。盛颖从一开始就校准了讨论的精确度——她经历的不是显性的歧视，而是一种“很 subtle 的意识层面的不对称”，无处不在。

她从少年时代的竞赛经历讲起。她竞赛成绩一直名列前茅，各种大赛都是顶尖水平。但她发现了一个微妙的模式：

盛颖谈性别不对称的微妙体验（约 01:35:35）

盛颖：如果我是个男生，大家就会说我是天才。如果我是个女生，他就会说她很努力，她很听话，你很用功……或者你运气好。

盛颖：我身边的人会找无数个理由来解释我为什么好。他们觉得你赢是不应当的。如果换一个人，那个赢是理所应当的。但如果是我赢了，他们会觉得你这个赢需要被解释。

盛颖：但是你正常情况下，一个人赢是不需要被解释的。我为什么要去 explain 他为什么赢？他厉害呀。但是我的每一场赢都要被解释。

她举了具体的例子：每次她赢了，周围人都会找原因——“对手最近状态不好”、“这个题她以前做过”、“她压中了题”。下一场赢了，又有新的解释。这些解释的共同特征是：它们都在回答“她为什么赢”，而从不问“他为什么输”。

盛颖谈”赢需要被解释” (约 01:36:25)

盛颖：每一场赢都要被解释。被我都个原因叫做”我为什么赢”，而不是”你为什么输”。

陈茜：让人很窒息。

盛颖：也不是故意的恶意。

最后一句话——”也不是故意的恶意”——是整段话的关键。这不是有人蓄意打压，而是一种无意识的集体认知偏差。正因为它不是故意的，所以更难被指出、更难被纠正、更难被承认。

盛颖强调，这种微妙的不对称从竞赛时代延续到了博士阶段、研究生涯、项目合作中，源源不断，从未停止。她用了一个精确的数学化表述来说明其影响：

盛颖谈不对称的累积效应 (约 01:31:18)

盛颖：每一个例子你单拎出来它都非常小，但是它是那种在你生命中无时不刻、每天发生的频繁的小事。所以它对那些被影响到的人造成的影响，不是你听到一个例子的时候所感受到的冲击，而是把那一件小事的冲击乘上一亿倍。那才是对那个人生的真实的冲击。

盛颖：你单独去看的时候它们都很小，但是持续发生，每天发生，每分秒在发生。

她还提到一个更 subtle 的现象：一旦有一个男性合作者，外界就会自然地质疑——”这个 idea 会不会不是她的”。这种质疑不需要任何证据，也不需要任何恶意，它只是一个自动触发的认知模式。

”需要被解释的赢”——一种隐性偏见的结构

当某个群体的胜利总是”需要被解释”，而另一个群体的胜利被视为”理所应当”时，这不是个别事件的问题，而是一种系统性的认知框架。它的危害在于累积效应：单次冲击很小，但日复一日、年复一年的累积，会深刻改变被影响者的心理状态，也会固化旁观者的认知偏差。

面对这个结构性问题，盛颖给出的回答既务实又坚定。她不认为教育（education）能解决这个问题——真正的解决方案只有一个：**让入行者真正拥有权利。**

盛颖谈解决路径 (约 01:37:50)

盛颖：你要解决这一点只有一个方法，就是你让所谓的入行者，如果在这个 specific example 的话就是女性，真正拥有权利。除此之外没有别的办法。

盛颖：你就是不断去赢就好了。

”不断去赢”——这不是鸡汤，而是一个在反复经历”赢都需要被解释”之后得出的冷静结论。当你在 top 0.001%、0.01%、0.1%、1% 的每一个层级都实现了平权，偏见才会被结构性地改变。

而关于更广泛的社会改变，盛颖提出了一个”递归传播”的方法论：

盛颖谈递归改变 (约 01:34:00)

盛颖：哪怕你培养更多的学生成为老师都是不够的。你要培养的是想要去培养、把学生培养成老师的老师。你就要把那个 recursive 的链条建起来才有用。

盛颖：这个事情它会非常非常的慢。但是它的好处是，你如果能做到一点，它就做到了。它不是会回退的改变。它是一个 gradual 的——你往前推了，它就是往前推了。solid improvement 就可以了。

这个“递归传播”的思路揭示了盛颖对变革的深层理解。直接帮助弱势群体解决不了结构性问题；培养能帮助弱势群体的人，效果也有限；真正有效的是培养“能培养帮助弱势群体的人”的人——建立一个递归的链条。这个过程极其缓慢，但每一步都是不可逆的 solid improvement，不会回退。

递归改变的方法论

盛颖提出的社会改变策略具有递归结构：不是直接解决问题（太局部），不是培养解决问题的人（扩展性不足），而是培养“培养解决问题的人”的人。这条链条一旦建立，每一步改变都是 permanent 的——它不会回退。代价是极慢，但收益是 solid。这个思路与她做基础设施的工程哲学一脉相承：不追求 big jump，追求每一小步的 move 都是 solid 的。

5.6 本章小结

本章从三个维度展现了盛颖的价值内核。第一，开源信仰不是后天选择而是成长环境的自然产物——被匿名分享者养大的人，不分享才是反常。第二，AI 的去中心化不是商业口号而是人类面对强 AI 时代的生存前提——只有先让所有人平等共处，人类才能团结起来寻找与 AI 共存的路径。第三，性别不对称不是显性歧视而是“一件小事乘以一亿倍”的累积效应——解决它不靠教育而靠真正的权力平等，推进它不靠 big jump 而靠 recursive 的、solid 的、不可逆的改变。

这三个主题看似分属不同领域，但共享同一个底层逻辑：**结构性的公平比表面的繁荣更重要**。无论是开源生态中纯粹与功利的较量，还是 AI 资源分配中集中与去中心化的博弈，还是科技行业中“赢需要被解释”的隐性偏见，盛颖都在试图从结构层面而非个案层面去推动改变。这也是她说“我不能改变，但如果我能改变 1% 的话，我愿意用我的一生去改变这 1%”的真实含义。

6 总结与延伸

6.1 世间的美好：波折之后的正反馈

在访谈的尾声，盛颖分享了一段深刻的人生体悟。她回顾了自己的博士求学、开源创业、融资经历——这三段旅程都充满了波折与不确定性，但最终都抵达了令人欣慰的终点。

博士第一年的导师轮转并不顺利，但最终遇到的 Clark Barrett 教授是“教科书般完美的导师”。开源项目 SGLang 一开始也遭遇了各种打击和质疑，但走到今天团队充满能量和热情。融资过程曲折反复，但最终合作的投资人也回归了书本中描述的那种理想关系——“终身友谊、并肩作战”。

关于世间的美好（01:42:37–01:43:28）

盛颖：世界上存在那么纯粹、那么好的导师，存在那么好的投资人，存在那么好的采访者。但是绝大多数人，他们没有坚持到把那个跌宕起伏的过程走完，没有坚持到相信那个好的东西其实是存在的。只是说你要筛选，只是说你要耐心，等着它最后显露出来。你要有这个耐心，让那些其实不是理想状态的杂质自己脱落掉。

这段话的核心洞见在于：理想状态不是不存在，而是需要足够的耐心和信念去等待它浮现。大多数人在中途就开始怀疑、放弃，从而错过了最终的正反馈。盛颖的经历恰恰证明了这一点——每一段波折的终点，都意外地验证了最初的信念。

正反馈循环与长期主义

盛颖描述了一种递增的信念循环：第一次等了几个月被验证，第二次等了几年被验证，第三次等了十年被验证。每一次验证都延长了她下一次坚持的耐力。这种正反馈循环是一种稀缺的心理资本——它让人在面对更长周期的不确定性时，依然能够保持信念。

6.2 逻辑自洽与情感割裂

作为一个逻辑极为缜密的人，盛颖坦然面对一个矛盾：世界本身是混乱的、不讲逻辑的——“世界是个草台班子”。她如何与这种割裂共处？

她的回答展现了一种罕见的自洽：情绪波动与价值观构建可以分离。她承认自己“非常 emotional”，微小的事情会造成巨大的情绪影响。但这些情绪冲击不会动摇她的核心信念体系——看到不好的事情发生，她会不高兴，但不会因此认为那就是正常的。

关于割裂与自洽（01:44:01–01:46:00）

盛颖：我在我的逻辑里是自洽的。我的逻辑不受我看到的事情的干扰。suffer 也有，我其实很 emotional……但是我能够把情绪影响跟我的价值观构建分离开。

盛颖：就算我整个人生都很割裂，我也不想妥协。……有这个割裂其实是完全 OK 的，它不会真的很痛苦。人们只是害怕而已。但如果说有个人告诉你说，就这样就这么回事，没关系——其实就真的没关系。

关于坚持的边界

盛颖也坦诚地回应了主持人的追问：并非所有人的坚持都一定能等到回报。有些人可能对自己的认知有误，可能不是“最正确的那个人”。但她强调，重点不在于是否正确，而在于是否按照自己的意志去认知和行动——“你只要不觉得自己在妥协，都没关系。哪怕你真的错了，就错了吧，也没关系。”这是一种对个体意志的深层尊重。

6.3 核心思想提炼与延伸思考

纵观整场 107 分钟的深度对话，盛颖的叙述中浮现出五个相互交织的核心主题：

五大核心主题

1. **顺应天赋而非对抗自我**：从 ADHD 的自我认知到“顺着天赋做事”的顿悟，再到在 Infra 领域找到热情——盛颖的成长轨迹始终围绕着“找到自己的频率”展开。
2. **Infra 即产品**：在一个以模型性能为王的行业里，盛颖坚持认为基础设施不是 support 角色，而是值得被精心设计的独立产品。这种“Infra First”哲学是 RadixArk 的核心文化。
3. **开源如空气**：开源不是策略选择，而是从小在互联网上自学编程时就自然形成的价值观。分享知识像呼吸一样自然。
4. **去中心化的 AI 平权**：不是所有东西都应该开源，但制造 AI 的能力不应该被少数巨头垄断。RadixArk 的使命是提供工具，让所有人都能创造属于自己的 AI。
5. **赢，不需要被解释**：从竞赛少女到科技创业者，盛颖一直在用行动证明：真正的实力不需要外部理由来合理化。这也延伸为对平权的深层理解——让弱势群体真正拥有权力，而非仅仅通过教育来改变认知。

对 AI 从业者的启示。 盛颖的经历对当下的 AI 从业者有几点具体启示：

第一，**基础设施的重要性被系统性低估**。在模型竞赛白热化的今天，推理引擎、训练框架、后训练工具链等基础设施层正在成为 AI 时代的核心技术层——连接芯片与模型、连接研究与产品。SGLang 和 RadixArk 的快速崛起印证了这一点。

第二，**开源社区的可持续性是一个未解的难题**。SGLang 的经历表明，纯粹的志愿者社区在项目快速增长长期难以维持质量和交付节奏。如何在商业化与社区精神之间找到平衡，是每个成功开源项目必须面临的挑战。

第三，**自我认知是职业发展的底层能力**。盛颖从形式化验证转向 AI 系统、从算法转向 Infra、从学术转向创业——每一次转型的背后都是对自身优势和热情的清晰认知。在一个快速变化的行业中，知道自己适合什么比追逐热点更重要。

6.4 拓展阅读

- SGLang 项目：<https://github.com/sgl-project/sglang>——盛颖创建的开源推理引擎，支持结构化生成和 RadixAttention 等核心技术。
- LMSYS 组织：<https://lmsys.org/>——盛颖与连敏共同创立的非营利组织，致力于开放 AI 研究和 LM Arena 评测平台。
- 硅谷 101 上期视频：推荐配合观看关于 SGLang 技术原理解释性视频，了解 AI Infra 如何“把 GPU 的极限给炸出来”。