


课程笔记：压缩即智能 Part 1——重新发明熵

3Blue1Brown (Grant Sanderson) · 中文笔记整理

2026 年 8 月 15 日



视频作者/频道：3Blue1Brown (B 站官方双语频道)

发布日期：B 站 2026-07-14 (原版 YouTube 2026-06-07)

视频时长：32 分 19 秒

视频链接：<https://www.bilibili.com/video/BV1yVNU6xERx>

PDF 制作 Skill：<https://github.com/wdkns/wdkns-skills>

目录

1 引言：压缩极限与“压缩即智能”	3
1.1 一个看似简单的问题：文本压缩的极限在哪里	3
1.2 信息论与机器学习：出人意料的联系	3
1.3 一个更稳妥的论断与三部曲的规划	4
1.4 本章小结	4
2 热身：月球机器人的四条指令	5
2.1 问题设定：非均匀分布的四条指令	5
2.2 学生一（直率）：朴素的固定 2 比特编码	5
2.3 学生二（聪明）：变长编码与 1.75 比特	5
2.4 前缀自由码：机器人如何知道在哪里切分	7
2.5 二叉树的视角：码字在“吃掉”可能性空间	8
2.6 数据大小与概率的第一次对齐	9
2.7 本章小结	10
3 完美压缩长什么样	10
3.1 学生三的洞见：随机噪声不可压缩	10
3.2 接收者的视角： 2^n 个等可能消息	11
3.3 “地毯鼓包”论证：省一比特，赔两比特	11
3.4 等可能消息的最优方案	12
3.5 本章小结	12
4 定义信息	13
4.1 从完美压缩到基本公式 $-\log_2(p)$	13
4.2 直觉：把可能性空间对半切	13
4.3 香农的信息定义：饼图与信息条	14
4.4 信息作为压缩下界	15
4.5 本章小结	15
5 语言的信息量	15
5.1 从机器人到语言：上下文依赖与分数比特	15
5.2 GPT 给出的逐字母概率	16
5.3 链式法则：整句概率 = 条件概率之积	17
5.4 谁提供概率？香农的 n-gram 统计	18
5.5 香农与贝蒂：猜字母实验	19
5.6 本章小结	20
6 定义熵	21
6.1 平均信息量：每符号多少比特	21
6.2 面积的直观：矩形面积之和	21
6.3 直觉游戏：均匀 vs 倾斜	22
6.4 无噪声编码定理	24
6.5 熵率：语言的熵	24

6.6	英文的熵：每字符约 1 比特	25
6.7	本章小结	25
7	总结与延伸	26
7.1	演讲者的收尾与预告	26
7.2	核心论证链的提炼	26
7.3	延伸：交叉熵预告	26
7.4	拓展阅读	27

1 引言：压缩极限与“压缩即智能”

1.1 一个看似简单的问题：文本压缩的极限在哪里

把文本编码成二进制时，我们自然希望用的数据越少越好。默认的 ASCII 编码非常低效：每个字符固定占 8 个比特。稍微动点脑筋，把常见字符映射到更短的比特串，平均可以压到每字符约 4 比特；更聪明的、利用长文本序列中模式的方法还能进一步压缩。于是问题自然地浮现出来：**文本压缩的效率是否存在某种根本极限？**

视频开场画面展示了这句追问（图 1）：一段文本被编码成比特串，旁边标注着“Limit?”（极限在哪？）。




图 1：压缩极限之问：把文本编码成比特串，究竟能压到多短？¹

格兰特·桑德森 (Grant Sanderson) 猜测很多观众听过某个具体估计值（他会在视频最后分享），但比任何单一数字答案更有意思的是**如何着手回答这个问题**。这个问题至少可以追溯到 1940 年代——克劳德·香农 (Claude Shannon) 开创信息论的开创性工作。

1.2 信息论与机器学习：出人意料的联系

真正有趣的是，香农为回答这类问题发展出的数学，对现代机器学习竟然出奇地有用。以今天最突出的例子来说：大语言模型 (LLM) 预训练阶段通常被描述为**下一个词元预测** (next token prediction)，具体使用一种叫做**交叉熵损失** (cross-entropy loss) 的目标函数。而“交叉熵”这个词的根源就在信息论里。

信息论的一个结论更加意味深长：**预测与压缩在数学上是等价的**——它们是一枚硬币的两面。这意味着，我们可以彻底换一种视角看待 LLM 的预训练目标：它本质上不是在“预测下一个词元”，而是在**制造一台尽可能高效的文本压缩器**。

¹ 视频画面时间区间：00:00:32–00:00:44。

核心观点：预测 $\Leftrightarrow$ 压缩

信息论的核心结论之一是：预测（用前面的内容推断下一个符号）与压缩（用尽量少的比特表达一段文本）在数学上是同一件事。LLM 预训练因此可以重新表述为：**学习一个能把训练语料压到最短的压缩算法**。理解交叉熵为什么被用作训练目标，关键在于先理解这条等价关系。

桑德森坦言，“用压缩作为追求智能的根本目标”这件事本身就极具吸引力。有些人甚至走得比这更远，直接宣称：**压缩即智能**（Compression is Intelligence，图 2）。




图 2: “Compression is Intelligence”——压缩即智能，本系列视频的出发点。²

1.3 一个更稳妥的论断与三部曲的规划

严格地评判“压缩即智能”很难，因为“智能”本身是个模糊、缺乏严格定义的概念。更稳妥的说法是：**压缩的数学理论对人工智能出奇地相关**。尽管如此，这个简洁的口号引人深思，因此它成为三部曲系列的第一部，目标是铺好评估这一论断所需的数学地基。

接下来约 30 分钟里，视频要带着观众专注于理解**压缩的极限**，并且让观众产生一种“我本可以自己重新发现香农无噪声编码定理”的感觉。做到这一点的关键是重新发现几个关键定义——**信息** (information) 与**熵** (entropy)。

把“定义”说成是“被发现的”听起来有点奇怪，但伟大的定义往往是某种洞察的残留物。这两个词并不难“定义”（直接甩一个公式很容易），但那样做会毁掉一个好故事。更有趣的是看看：当你追问“压缩语言的极限”时，是如何被不可避免地引导到它们面前的。最后请注意一个伏笔：要回答这个问题（至少香农无法回避），**必然要触及某种“智能”的概念**。

1.4 本章小结

- 文本压缩效率存在极限问题，起源于 1940 年代香农的信息论。

²视频画面时间区间：00:01:55–00:02:00。

- 预测与压缩数学等价，LLM 预训练可重新表述为“制造最有效的文本压缩器”。
- “压缩即智能”难以严格评判，但压缩的数学理论与 AI 惊人相关。
- 本视频目标：重新发现“信息”与“熵”的定义，进而理解无噪声编码定理。

2 热身：月球机器人的四条指令

2.1 问题设定：非均匀分布的四条指令

正式建模语言之前，先用一个更简单、但包含同样核心思想的例子热身。想象一个被送往遥远月球的机器人，它的任务是漫游地表收集数据。我们从地球上给它发送移动指令，指令只有四种简单可能：上 (up)、下 (down)、左 (left)、右 (right)，每一步固定步长。

关键在于这些指令并非均匀分布：我们发送的所有指令中一半是“上”，四分之一是“下”，八分之一是“左”，八分之一是“右”（图 3）。为了简单，还假设每条指令都是**独立**的——无论前面的上下文如何，都从这个分布中抽样。




图 3: 机器人指令的概率分布：上 $1/2$ 、下 $1/4$ 、左 $1/8$ 、右 $1/8$ 。³

向遥远的机器人发送数据是比特流 (0 和 1)，传输又慢又贵。因此今天的热身谜题是：**把这四种指令编码成比特流，最有效的方式是什么？**视频引入了三位学生，分别代表三种层次的思考：一位直率 (straightforward)、一位聪明 (clever)、一位非常理论化 (head in the clouds)。

2.2 学生一 (直率)：朴素的固定 2 比特编码

第一位学生立刻举手：四种指令，每种用 2 个比特就行了——比如 00 表示上、01 表示下、10 表示左、11 表示右。在接收端，机器人解码非常容易：把比特流按每 2 位切块，逐块翻译成指令即可。平均下来是**每条指令 2 比特**。

2.3 学生二 (聪明)：变长编码与 1.75 比特

第二位学生指出：固定 2 比特完全没有利用“上”远比“左”、“右”频繁这一事实。他提出给每条指令分配**不同数量的比特**：

³视频画面时间区间：00:03:51–00:04:00。

指令	概率	码字
上	1/2	0
下	1/4	10
左	1/8	110
右	1/8	111

平均每条指令需要的比特数用加权和计算（图 4 展示了朴素方案与优化方案的对比）：

$$\frac{1}{2} \times 1 + \frac{1}{4} \times 2 + \frac{1}{8} \times 3 + \frac{1}{8} \times 3 = 1.75 \text{ 比特/指令}$$




图 4: 朴素方案（每条 2 比特）与聪明方案（变长编码）的对比。⁴

第二位学生在后两条指令上多花了比特（3 位），但因为它们出现频率低得多，最常用指令只用 1 比特就完全弥补回来了。这个效率也可以经验验证：从该分布抽样一组指令，按这套编码转成比特串，结果确实比朴素方法短（图 5）。

⁴视频画面时间区间：00:05:37–00:05:47。




图 5: 实际抽样的指令序列：可以看到“上”很多、“下”约一半、“左”“右”更少；编码后比特串确实更短。⁵

2.4 前缀自由码：机器人如何知道在哪里切分

聪明的学生方案立刻引出一个尖锐的问题：**机器人怎么知道在哪里画分界线**？一旦允许不同指令用不同数量的比特，解码就不再显然——接收端必须知道每个码字在哪里结束。

关键在于：机器人只需持续读入比特，直到凑成一个完整的码字，就登记一条指令（图 6）。要做到这一点，必须满足一个约束：**没有任何码字是另一个码字的前缀**。



图 6: 解码过程的逐步演示：比特流被切分成 $10|0|110|0|110|\dots$ ，每凑齐一个完整码字就登记一条指令。⁶

⁵视频画面时间区间：00:06:24–00:06:42。

⁶视频画面时间区间：00:07:05–00:07:52。

比如收到第一个比特是 1：它可能是“下”、“左”、“右”任意一个的前缀；若紧接着是 0，则只能是“下”（没有别的可能）；若是再一个 1，仍然歧义（“左”“右”的前缀）；直到第三个比特是 0，才能确定这三比特是“左”。反例更说明问题：如果引入第五条指令、码字取 100，读完 10 后无法区分这是“下”还是新指令的开头——歧义产生了。

术语：前缀自由码 (prefix-free code)

避免这种冲突的编码方法有个专门名字：**前缀自由码** (prefix-free code)，更常见的叫法反而容易混淆——**前缀码** (prefix code)。它指的是：码字集中没有任何一个码字是另一个码字的开头（前缀）。一旦满足该性质，变长码就能从左到右无歧义地逐码字解码。

2.5 二叉树的视角：码字在“吃掉”可能性空间

前缀自由码的选取可以用一张漂亮的图可视化——它表示所有可能的二进制串（图 7）。每一层展示某一长度的全部比特串：以 0 开头的都在左半，以 1 开头的都在右半；递归地，以 00 开头的位于左上四分之一，依此类推。关键性质：**图中的每个二进制串，都是它上方所有串的前缀。**




图 7：所有二进制串构成的树状图：每一层是某一长度的全部比特串，每个串都是其上方所有串的前缀。⁷

聪明学生把单个比特 0 分配给“上”，等于**吃掉了全部可能码字空间的一半**——因为前缀自由性质禁止一切以 0 开头的串再作他用。类似地，“下”=10 吃掉四分之一空间，“左”=110 与“右”=111 各吃掉八分之一（图 8）。空间恰好被填满，一点不剩。

⁷ 视频画面时间区间：00:08:52–00:09:32。




图 8: 码字在树上占据的空间: 0 占一半、10 占四分之一、110/111 各占八分之一, 恰好填满。⁸

2.6 数据大小与概率的第一次对齐

看到这里, 读者脑中应该响起某种铃声: 这些比例与每条指令出现的概率完全一致—— $1/2$ 、 $1/4$ 、 $1/8$ 、 $1/8$ 。码字长度恰好匹配概率的“压缩空间份额”(图 9)。




图 9: 码字占用的空间份额与指令概率精确对齐: 数据大小与概率之间存在着根本联系。⁹

⁸视频画面时间区间: 00:09:36–00:10:00。

⁹视频画面时间区间: 00:10:02–00:10:22。

这种“数据大小与概率之间关系”的痒痒感，正是**信息论的奠基性洞察**。盯着这令人愉悦的对齐，你可能会想：聪明学生的方案不只是更好，也许某种意义上是**完美的**。但要宣称“完美”还太早——怎么知道不存在某种超聪明的方法，对很长的指令序列要花招，把平均比特数压得更低？这引出了第三位学生。

奠基洞见：数据大小与概率相关

码字分配的空间份额 = 该符号出现的概率。这是信息论的第一块基石：**高频符号应使用短编码**。反过来，编码长度与概率之间的精确关系式，将引出“信息”的定义。

2.7 本章小结

- 非均匀分布下，固定长度编码浪费空间；变长编码平均 1.75 比特/指令，优于固定 2 比特。
- 变长码可解码的关键：前缀自由性质（无码字是另一码字的前缀）。
- 二进制串树状图给出直观：每个码字吃掉与其概率成正比的空间份额。
- 数据大小与概率的对齐是信息论奠基洞见——为“信息”定义埋下伏笔。

3 完美压缩长什么样

3.1 学生三洞见：随机噪声不可压缩

第三位学生（天马行空型）没有去想能实现的真实编码，而是在琢磨：一个**完美、最优的编码应该具有什么性质**？他有一个非常聪明的想法：随机噪声应该是不可压缩的，因此**完美压缩算法的输出应该与随机噪声不可区分**。这听起来简单，却能引导你重新发明香农熵。

所谓随机噪声，指每个比特以 50% 概率为 0 或 1，且所有比特互相独立（图 10）。不难证明第二位学生的机器人编码确实满足这条性质：消息有 50% 概率以“上”开头（首比特 50% 为 0，否则为 1）；若首比特是 1，又有 50% 概率是“下”（下一比特为 0），依此类推。每个新比特真的像一次独立抛硬币——对接收者来说，压缩后的比特流确实与随机噪声不可区分。




图 10: 随机噪声的定义：每个比特 50/50 独立出现，没有任何可预测结构。¹⁰

3.2 接收者的视角： 2^n 个等可能消息

为什么随机噪声不可压缩？把视角切换到接收者，并且不再一条指令一条指令地思考，而是把讨论提升到**完整消息**的层面。当接收者看到代表某条压缩消息的 n 位比特串时，这是 2^n 个可能消息之一（图 11）。关键是：因为假设输出看起来像随机噪声，这 2^n 个消息**必须等可能**。




图 11: n 位压缩消息是 2^n 个可能消息之一；若像随机噪声，它们全部等可能。¹¹

注意这里的推广：第三位学生想为**任何数据类型**（语言、图像……）论证完美压缩的样子，且论证要与具体压缩算法无关。直觉上，压到 n 位的众多消息中，有些原本是大量可预测数据，有些原本是少量不可预测数据。但如果压缩后的比特流真的像随机噪声——所有 n 位串等可能——那么被压缩的底层消息**也必然等可能地出现**，且概率精确为 $1/2^n$ 。

3.3 “地毯鼓包”论证：省一比特，赔两比特

回到表示所有二进制串的树状图：把 2^n 个等可能消息的编码看作某一层上的比特串。如果试图更高效，让其中一个消息用更少的比特——它在图中下移，于是**与别的消息重叠**；那个被挤占的消息必须挪到别处，至少要再挤占第三个消息，被挤的这两个不得不上**移一层**，各多花 1 比特来消歧（图 12）。

¹⁰ 视频画面时间区间：00:11:17–00:11:25。

¹¹ 视频画面时间区间：00:12:15–00:12:25。




图 12: “地毯鼓包”论证：把某个消息的编码往下移省 1 比特，会挤占其他消息、逼它们上移，每移一个多花 1 比特。¹²

所以：**在这里省 1 比特，就要在别处赔 2 比特。**你就像把地毯上的鼓包按下去，结果它在另一个地方更糟地鼓起来。一般地，任何在图中较低位置的消息都在吃掉超出其份额的空间，迫使多个其他消息挤进更小区域、被顶到更高层，编码得更低效。

3.4 等可能消息的最优方案

对等可能消息，最有效的方案直觉上显然是把它们全部编码成**相同位数**；而树状图给出了更具体的理由：否则必然产生不利的权衡。于是得到第一个重要结论：

完美压缩的性质

完美压缩的输出与随机噪声不可区分：所有 n 位消息等可能 $\Rightarrow$ 所有被压缩的底层消息等可能、概率均为 2^{-n} 。对等可能消息，最优编码是给它们相同数量的比特。

3.5 本章小结

- 随机噪声不可压缩；完美压缩的输出应当与随机噪声不可区分。
- 从接收者视角： n 位压缩消息是 2^n 个等可能消息之一。
- 树状图论证：压低一个消息必挤高其他消息——省 1 比特赔 2 比特。
- 等可能消息的最优方案是相同位数；这一性质将引出“信息”的定量定义。

¹²视频画面时间区间：00:13:30–00:14:15。

4 定义信息

4.1 从完美压缩到基本公式 $-\log_2(p)$

一旦接受了“完美压缩看起来像随机噪声”，就会自然地走到定义面前——这正是视频开头所说的“洞察引导出定义”。本质上我们在说：完美方案中使用 n 比特的消息，其出现概率必为 $1/2^n$ ，即 2^{-n} 。两边取以 2 为底的对数再取负：

$$p = 2^{-n} \iff n = -\log_2 p$$




图 13: 推导过程： n 比特消息的概率是 2^{-n} ，于是 $n = -\log_2 p$ 。¹³

$-\log_2 p$ 是整个信息论的基本公式。视频至此所做的一切，都是为了让这个值感觉像“你被完美压缩的问题不可避免地吸引而来”的东西，而不是一个凭空开始的任意定义。

4.2 直觉：把可能性空间对半切

“负对数”需要一点时间适应：看起来像是负值，但中间的分数的关键。直观的读法是：它问的是——要把你的可能性空间对半切多少次，才能到达某个量。比如 $p = 1/8$ 意味着切 3 次 ($1 \rightarrow \frac{1}{2} \rightarrow \frac{1}{4} \rightarrow \frac{1}{8}$)，信息就是 3 比特。图 14 画出了 $-\log_2 p$ 的图像。

¹³ 视频画面时间区间：00:15:07–00:15:20。




图 14: $-\log_2 p$ 的图像：概率越小，信息值越高；概率接近 1，信息接近 0。¹⁴

log 的三种等价写法

同一个量有三种常见写法，含义相同：

$$-\log_2 p = \log_2 \frac{1}{p} = \log_{1/2} p$$

第一种最常见；第二种对“倒数的对数”更直观；第三种（以 1/2 为底）几乎没人用，但桑德森个人偏爱它——因为它直接读出“对半切多少次”。

4.3 香农的信息定义：饼图与信息条

香农意识到，即使无法实现字面上的完美压缩、 p 不再是 2 的干净幂次时，这个表达式仍然是思考“一条消息包含多少信息”的极好方式（输出会是某个分数值）。他直接把该表达式定义为一个事件的信息量（information of an event）。

桑德森给出的心智图像：把事件概率画成小饼图，信息是饼图上方的一条竖条——概率被挤向 0 时竖条被“泵”得更高；概率接近 100% 时竖条放松变矮（图 15）。也就是说：罕见消息包含大量信息，高预期消息包含极少信息。

¹⁴ 视频画面时间区间：00:15:55–00:16:06。




图 15: 信息量的可视化：饼图表示概率，上方竖条高度为 $-\log_2 p$ 。概率越小，信息条越高。¹⁵

这个定义有**实质内容**，不只是把概率重新缩放一下（像是换成另一种单位制）。核心思想在前面已经见过：完美压缩方案中，分配给完整消息的比特数**恰好等于**它的信息含量。

4.4 信息作为压缩下界

当然，完美压缩并不总能实现——消息概率往往不是 2 的幂。更一般的表述是：**一条消息的信息量给出了它可被压缩程度的下界**——至少在对所有可能消息取平均时成立。这需要小心一处陷阱：

常见误区：可以过拟合单条消息

“信息 = 压缩下界”是**对消息整体平均**而言的统计规律，不是针对某一条特定消息的保证。完全可能把压缩算法“过拟合”到某一个具体案例上，让它在那一例上表现特别好——但那不构成对平均极限的违背，也不是通用的压缩方案。

4.5 本章小结

- 完美压缩 $\Rightarrow$ 消息概率 $p = 2^{-n}$ ，于是信息 $= -\log_2 p$ ，这是信息论的基本公式。
- 直觉：信息 = 把可能性空间对半切的次数；分数比特在一般概率下依然成立。
- 香农定义：事件的信息量；罕见事件信息多，高预期事件信息少。
- 信息是平均意义下的压缩下界，可过拟合单条消息但不影响极限。

5 语言的信息量

5.1 从机器人到语言：上下文依赖与分数比特

要真正理解信息与分数比特，需要超越热身例子。机器人的概率太“干净”了——全是 2 的幂，每个符号的信息恰好是整数比特。但香农真正关心的是**更现实、更复杂的案例**：自然语言。

¹⁵ 视频画面时间区间：00:16:40–00:16:57。

语言与机器人编码有两大区别。第一，**上下文依赖极强**：每个新字母的概率分布高度取决于它之前的一切。第二，这些概率**显然不会是干净的 2 的幂**。因此计算每个字母的香农信息 ($-\log_2 p$) 时，得到的是各种分数值。

5.2 GPT 给出的逐字母概率

视频用本地运行的一个小 GPT 演示：对示例短语逐字母给出概率分布（图 16）。桑德森特意提醒：模型给出的概率与“语言的真实概率”很可能不是一回事——这个念头先记着，后面非常相关。




图 16: 本地 GPT 对示例短语逐字母给出的概率分布，与机器人例子的 $1/2$ 、 $1/4$ 、 $1/8$ 截然不同。¹⁶

给这些值一个模糊的解释很容易：高度可预测的字母信息含量低，高度不可预测的字母信息含量高（图 17）。但观众足够聪明，会要求更精确的解释——一个能证明这些值凭什么配得上“比特”这个单位的解释。毕竟不可能存在某种完美编码，让字母 i 恰好拥有 4.19 比特的码字，或让高可预测的 o 用“一丝比特”编码。

¹⁶ 视频画面时间区间：00:18:04–00:18:12。




图 17: 逐字母的分数信息值: $p \rightarrow -\log_2 p$ 映射, 许多字母的信息是 0.09、2.93 之类的分数。¹⁷

5.3 链式法则: 整句概率 = 条件概率之积

真实含义与**编码整条消息**有关。整句短语的概率等于每个连续新字母概率的乘积——其中每个概率都以之前的内容为条件。这正是概率论中的**链式法则** (chain rule, 图 18):

$$P(w_1 w_2 \cdots w_m) = \prod_{i=1}^m P(w_i | w_1 w_2 \cdots w_{i-1})$$




图 18: 链式法则: 整句概率 = $P_0 \cdot P_1 \cdot P_2 \cdots P_n$, 每个因子都是条件概率。¹⁸

¹⁷ 视频画面时间区间: 00:18:45–00:18:52。

注意对数与这个乘积配合得多漂亮：因为对数把乘法变成加法，整条消息的信息量（取负对数）就优雅地分解成**每个字母信息量之和**：

$$I(\text{整句}) = -\log_2 \prod_{i=1}^m P(w_i | \dots) = \sum_{i=1}^m I(w_i)$$

在系列第三部，桑德森会演示一种具体的压缩算法（算术编码的变体），它能把这句文本压到该值 **1–2 比特以内**。届时不再是“每个字符映射到预定义码字”那么简单，但你会有非常直接的感受：把每个字母的分数信息量加起来，就决定了最终编码的长度。这就是关键思想——即使最终落实到真实数据大小时要四舍五入成整数，香农认识到，在**信息可以连续取值、逐事件相加**的这个更高抽象层上工作极其有用。

5.4 谁提供概率？香农的 n-gram 统计

严肃评估语言的**根本可压缩性**时，一切都取决于：**你怎么知道每个连续字母的概率**？视频里的动画用语言模型来演示，但这既不等于语言的真实概率，而且“语言的真实概率”到底指什么也不清楚。于是桑德森带观众回到过去，看看没有语言模型、没有现代数据分析时，香农自己是怎么想的。

香农最早的语言信息实验之一：考察特定的短字符序列（即常说的 **n-gram**），跟踪其后跟随字符的统计。例如扫描几本书，每当出现“th”就记录后面跟着什么字母，就能建出一张表（图 19），用这些统计代表所关心的概率。



图 19: 香农的 n-gram 统计：记录“th”后面经常跟着的字母（THE、THOSE、THIS、THAN……）。¹⁹

问题在于：对更长的字母串，这种方法彻底失效——尤其是**任何在所有书里都没出现过的文本串**。尽管如此，讨论“更长的串后面预期跟着什么”依然完全合理；甚至更重要——**上下文窗口越长，可预测性越强，能靠可预测性赚到的压缩也越多**。

¹⁸ 视频画面时间区间：00:19:30–00:20:03。

¹⁹ 视频画面时间区间：00:21:36–00:21:48。

5.5 香农与贝蒂：猜字母实验

于是，香农改用另一种他手头可用的“英语模型”——他的妻子贝蒂（Betty）。据记载，香农拿出一本书，让贝蒂逐个猜下一个字母，然后逐字母记录她的猜测：猜错就写下正确字母，猜对就用一个破折号代替（图 20）。




图 20: 猜字母实验的转录结果：猜对的字母被替换成破折号，文本大幅缩短但仍包含足够信息。²⁰

他的观点是：这份转录文本比原文的字母少得多，但**含有同样多的信息**——至少在以下意义上成立：如果能获得一个妻子的精确复制品，再次玩这个猜谜游戏，只需把这缩减后的文本给她，这些字母本身就提供了恰到好处的提示，让复制品妻子精确还原出原文（图 21 展示了实验所用的原文段落）。

²⁰ 视频画面时间区间：00:22:43–00:23:08。



图 21: 猜字母实验所用文本片段: “IN THE MIDDLE OF THE ROOM STOOD A BIG SQUARE TABLE LITTERED WITH PLAYING CARDS”。²¹

当然，实际中一个人两次未必猜得一样，这个实验定性地传达了“可预测性允许压缩”，但**还不是对信息的测量**。在 1950 年的论文《Prediction and Entropy of Printed English》（印刷英语的预测与熵）中，香农改进了实验设计：这次访谈了更多人，不再只记录猜对与否，而是记录**猜中正确字母需要多少次猜测**；再用一套方法把这些猜测次数关联到“人对真实下一字母赋予的隐含概率”。细节很繁琐，但更广的要点是：分析语言时，香农**不是在做纯数据统计**——他是在探测一个底层的语言模型，即**受访者的的大脑**。这些能交谈的大脑被当作黑盒：它们拥有复杂却无法描述的语言理解，能基于上下文预测字符。

从审问黑盒到设计黑盒

香农在 1940–1950 年代的做法：把人的大脑当作**可交互的黑盒语言模型**来探测。到了 2020 年代，我们已从仅仅“审问”处理语言的黑盒，进步到**设计它们**——大语言模型就是被训练来充当这种预测黑盒的。这条历史线索正是本系列把信息论与 LLM 联系起来的桥梁。

5.6 本章小结

- 语言概率高度依赖上下文且不是 2 的幂，逐字母信息是分数值。
- 链式法则：整句概率 = 条件概率之积；取对数后整句信息 = 逐字母信息之和。
- 分数比特的真实含义是整条消息编码长度的下界。
- 香农的探索：n-gram 统计失效后，用妻子贝蒂做猜字母实验（定性），再用多人访谈的猜测次数测出隐含概率（1950 年论文）。
- 香农在探测“大脑黑盒语言模型”——现代 LLM 正是这种黑盒的设计版。

²¹ 视频画面时间区间：00:23:20–00:23:32。

6 定义熵

6.1 平均信息量：每符号多少比特

回到这里的原因，是现代机器学习的数学大量利用了信息论中涌现的公式。除了“信息”本身的定义，还有三个关键表达式，桑德森希望观众感觉“自己也能重新发现”。第一个就是**熵**（entropy）——素材已全部齐备。

想象任何可以看作符号序列的信号：机器人的四条指令、英语、或任何你能想到的东西。**熵问的是：每个符号的平均信息量是多少？**基于前面的结论（完美压缩看起来像随机噪声、消息比特数 = 信息含量、整句信息 = 各符号信息之和），“每符号平均信息”正是压缩极限的下界。机器人的例子已经算过一遍：那 1.75 比特/指令的加权和，因为编码是完美的，每个符号的码字长度恰好等于其信息含量——所以那就是在计算**每符号平均信息**。

一般化：对任意刻画消息符号的概率分布，每符号平均信息为（图 22）：

$$H(X) = - \sum_i p_i \log_2 p_i = \sum_i p_i \log_2 \frac{1}{p_i}$$




图 22: 熵的构建：符号 $s_0, s_1, \dots, s_n$ 各有概率 $p_0, p_1, \dots$ ，每符号平均信息即熵。²²

6.2 面积的直观：矩形面积之和

视频全程用**堆叠的横条**可视化概率分布——每条横条的宽度等于其概率，加起来为 1。现在每条上面加一个矩形，高度锁定为对应的信息值 $-\log_2 p_i$ （图 23）。于是上方的加权和——每符号平均信息——就是**所有矩形面积的总和**。

²²视频画面时间区间：00:26:13–00:26:27。




图 23: 熵 = 所有矩形面积之和: 每条横条宽度 p_i , 矩形高度 $-\log_2 p_i$ 。²³

这个表达式**还不完全一般**: 它只描述“每个新符号都服从同一分布”的情况——机器人例子成立, 但英语不成立。尽管如此, 它重要到值得拥有一个名字。

冯·诺依曼命名“熵”的传说

据说约翰·冯·诺依曼 (John von Neumann) 建议香农把这个表达式叫做**熵** (entropy), 理由有二: 一是它类似统计力学中已有的熵表达式; 二是一句广为流传的名言——“没有人真正知道熵是什么, 所以在争论中你永远占上风”。桑德森考证后认为这故事多半是杜撰 (apocryphal), 但似乎有几分真实的成分。无论真相如何, 香农确实把它命名为熵, 并用字母 h 表示。

6.3 直觉游戏: 均匀 vs 倾斜

来玩玩这张图找直觉 (图 24): 分布越均匀, 总熵越高; 如果挤压成极不均匀——一个事件主导概率空间——熵就很低, 因为那个压倒性可能的事件携带的信息极少。把概率空间切得更碎 (分布在更多符号上), 每个符号信息更多, 总熵更高。来回晃动: 倾斜分布给低熵, 均匀分布给高熵。

²³ 视频画面时间区间: 00:26:32–00:27:00。




图 24: 熵的可视化: $H(P) = \sum p_i(-\log_2 p_i) = \text{面积}$, 此处 = 2.81 比特, 标注为 “Entropy”。²⁴

模糊的定性直觉是：熵衡量分布中的不确定性。更精确、配得上“比特”单位的理解是：熵描述编码一条来自该分布的、每个符号所需的最少比特数。图 25 用二元分布 $H_2(p) = -p \log_2 p - (1-p) \log_2 (1-p)$ 直观展示这条规律： $p = 1/2$ 最均匀时熵达到最大值 1 比特，越偏离均匀熵越低。




图 25: 二元分布的熵曲线（本笔记补充）：分布越均匀熵越高， $p = 1/2$ 时达最大值 1 比特；趋于确定时熵趋于 0。

²⁴视频画面时间区间：00:27:47–00:28:30。

6.4 无噪声编码定理

上面那句话加上全部前面的内容，基本就是香农 1948 年奠基论文中一个核心定理的内容——**无噪声编码定理**（noiseless coding theorem，图 26）：

无噪声编码定理（香农 1948）

对于服从某概率分布的独立同分布符号流：

- **下界**：没有任何编码能比熵 H 更高效——每符号平均比特数不可能低于 H ；
- **可达性**：总存在编码方案能任意逼近这个极限。




图 26：无噪声编码定理，以及香农 1948 年奠基论文《A Mathematical Theory of Communication》。
25

6.5 熵率：语言的熵

如前所述，该表达式只适用于“每个符号同一分布”的情形；而香农当然对更一般的设定兴致盎然——每个新符号的概率**不必**服从同一分布，尤其是他花了大量时间思考的**自然语言的可压缩性**。这需要更一般的熵概念：**随机过程的熵率**（entropy rate）：

$$h = \lim_{n \rightarrow \infty} \frac{1}{n} H(X_1, X_2, \dots, X_n)$$

这是同一个基本问题——每符号平均信息——只不过现在对所有可能消息取平均。它几乎永远不可能用刚才那种干净的可视化精确算出来：毕竟，**什么公式能描述语言的概率分布**？所以如果有人提到“语言的熵”，它远超任何精确计算所能给出的东西——这正是香农转向**基于观察的估计**的原因。而且再次强调，他的方法不是数据分析，不是对文本语料跑某个函数；要获得令人满意的可压缩性估计，他发现自己不可避免地需要**探测智能的语言模型**。

²⁵ 视频画面时间区间：00:28:50–00:29:09。

6.6 英文的熵：每字符约 1 比特

当受访者拥有至少 100 个前序字母的上下文时，香农估计英语的熵约为每字符 1 比特（图 27）。




图 27: 英文熵的估计：“Bits Per Character = 1.0”——每字符约 1 比特。²⁶

这个数字相当惊人：它意味着英语可以压缩到每个字符只需一个 yes/no 回答——每个字符平均只要 1 比特。听起来疯狂，但在第三部，桑德森会展示前面提到的那套算法：如果允许用高质量语言模型做编码与解码，实践中可以惊人地接近这个极限。在那之前，先理解熵的一个变体——交叉熵（cross-entropy）——以及它为什么、怎样被用于训练大语言模型（Part 2 的内容）。

核心结论：压缩极限的完整链条

完美压缩 = 随机噪声 → 信息 = $-\log_2 p$ (每事件) → 熵 = 每符号平均信息 (压缩下界) → 无噪声编码定理保证极限可达 → 语言的熵 (有上下文时约 1 比特/字符) 只能靠智能模型估计。预测与压缩的等价，让“用 LLM 压缩”成为“用 LLM 理解语言”的同义表述。

6.7 本章小结

- 熵 $H(X) = -\sum_i p_i \log_2 p_i$ ：每符号平均信息量，即压缩极限的下界。
- 可视化：熵 = 条形图上方矩形面积之和；分布越均匀熵越高。
- 无噪声编码定理：无编码能低于熵，且总能任意逼近熵。
- 语言需要更一般的熵率；香农估计英语熵 ≈ 1 比特/字符 (≥ 100 字母上下文)。
- 交叉熵 (Part 2 主题) 是把这套数学接到 LLM 训练上的关键。

²⁶ 视频画面时间区间：00:30:21–00:30:38。

7 总结与延伸

7.1 演讲者的收尾与预告

视频末尾，桑德森为系列铺路：在进入 Part 2 之前，先理解交叉熵这一熵的变体——它是如何、以及为什么被用于训练大语言模型。Part 2 还会涉及几个有趣的相关想法：大模型如何被蒸馏成小模型，以及**为什么 GZIP 能恢复不同语言之间的结构**。Part 3 则演示那套“用高质量语言模型编码解码”的算法，实证逼近每字符 1 比特的极限。全系列的立意，正如开场所说：为评估“压缩即智能”这一发人深省的口号，打下坚实的数学地基。

7.2 核心论证链的提炼

这 32 分钟实际上完成了一条完整的逻辑链，每一步都靠“重新发现”而非灌输：

1. **压缩极限之间**：文本压缩存在根本极限吗？（ASCII 8 比特 → 聪明编码 4 比特 → 更好方法……极限在哪？）
2. **完美压缩 = 随机噪声**：最优压缩的输出必须与随机噪声不可区分；否则说明还有可预测结构没被榨干。
3. **信息** $= -\log_2 p$ ：等可能消息的树状图论证，把“分配比特数”与“出现概率”焊死在一起；香农将其提升为一般定义，允许分数比特。
4. **熵 = 平均信息**：对分布取期望即得 $H = -\sum p_i \log_2 p_i$ ；无噪声编码定理保证它是极限且可达。
5. **语言的熵需要智能**：n-gram 统计失效后，香农只能靠“人脑黑盒”（贝蒂与访谈者）估计英语熵 ≈ 1 比特/字符。
6. **预测与压缩等价**：LLM 预训练 = 压缩文本；理解语言 = 更高效的压缩器。这为 Part 2 的交叉熵与 Part 3 的压缩算法铺好路。

其中第 5 步最值得回味：要测量语言的可压缩性，香农**不可避免要涉及某种智能**——这正是开场那句“压缩与智能纠缠”的数学化体现。而第 6 步把这条历史线索接到现代 LLM 上：我们如今不只是探测黑盒，而是**直接训练**黑盒去预测（即压缩）语言。

7.3 延伸：交叉熵预告

熵衡量“使用正确分布时每符号所需的最少比特”。若我们不知道真实分布 p ，却用另一个模型 q 去编码，实际平均每符号比特数是多少？答案是**交叉熵**：

$$H(p, q) = -\sum_x p(x) \log_2 q(x)$$

交叉熵的直觉（Part 2 预告）

交叉熵回答：“我用 q 这个（可能错误的）模型去压缩服从 p 的数据，平均每符号要花多少比特？”由 Gibbs 不等式， $H(p, q) \geq H(p)$ ，等号当且仅当 $q = p$ 。**LLM 预训练的最小化交叉熵损失，就是让模型 q 逼近语言真实分布 p ，也就是把语言压到最短**——“压缩即智能”在数学上的精确化。模型的“蒸馏”、GZIP 的语言聚类等话题，都建立在这条线上。

7.4 拓展阅读

- 香农 1948 年奠基论文: *A Mathematical Theory of Communication* (其中包含无噪声编码定理)。
- 香农 1951 年论文: *Prediction and Entropy of Printed English* (猜字母实验与英语熵的估计)。
- Chris Olah 的博客文章: *Visual Information*——视频中熵可视化方式的灵感来源。
- 3Blue1Brown 官网 FAQ 与系列后续 Part 2 (交叉熵)、Part 3 (逼近极限的压缩算法)。